



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Máster Universitario en Inteligencia Artificial

Trabajo Fin de Máster

**Evaluación Comparativa de Arquitecturas
Encoder y Grandes Modelos de Lenguaje
para el Reconocimiento de Entidades
Clínicas en Español**

Autor: Carlos Honrado Cristobalena

Tutor: Emilio Serrano Fernández

Cotutor: Sergio Rubio Martín

Madrid, Julio de 2026

Este Trabajo Fin de Máster se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Máster

Máster Universitario en Inteligencia Artificial

Título: Evaluación Comparativa de Arquitecturas Encoder y Grandes Modelos de Lenguaje para el Reconocimiento de Entidades Clínicas en Español

Julio de 2026

Autor: Carlos Honrado Cristobalena

Tutor: Emilio Serrano Fernández

Grupo de Ingeniería Ontológica (Ontology Engineering Group, OEG)

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Cotutor: Sergio Rubio Martín

Departamento de Ingeniería Eléctrica y de Sistemas y Automática

Escuela de Ingenierías Industrial, Informática y Aeroespacial

Universidad de León

Resumen

El Reconocimiento de Entidades Nombradas (NER) es una tarea del Procesamiento del Lenguaje Natural que consiste en localizar y clasificar términos dentro de textos no estructurados. En el ámbito biomédico, su aplicación permite la extracción automatizada de información clínica; sin embargo, la complejidad inherente al lenguaje médico plantea retos significativos. Históricamente, este campo ha estado dominado por modelos basados en el componente codificador de la arquitectura Transformer, como RoBERTa. No obstante, la creciente adopción de Grandes Modelos de Lenguaje (LLMs) generativos, basados en el componente decodificador de dicha arquitectura, hace necesario comparar ambos enfoques en términos de precisión y eficiencia.

Este Trabajo Fin de Máster evalúa esta cuestión en el dominio clínico en español utilizando los corpus DisTEMIST (enfermedades) y ProcTEMIST (procedimientos), basados en 1.000 casos reales. Se comparan cinco codificadores entrenados con técnicas supervisadas frente a seis LLMs de código abierto y GPT-4.1-mini, modelo propietario de OpenAI. Estos modelos se evalúan tanto en estrategias sin ajuste de parámetros, incluyendo aprendizaje en contexto con y sin ejemplos (*in-context learning*), como en ajuste fino supervisado con técnicas eficientes como QLoRA. Para garantizar la comparabilidad con las competiciones originales, se aplica la misma métrica empleada en dichas shared tasks, que exige identificar la posición exacta de cada término en el texto.

Los resultados muestran que los codificadores obtienen los mejores resultados, con un F1 estricto de 0,805 en ProcTEMIST y 0,797 en DisTEMIST. El mejor modelo abierto, Ministral-3-8B-Instruct, obtiene resultados similares tras el entrenamiento con QLoRA (0,793 en ambos corpus), próximos a los del modelo comercial GPT-4.1-mini (0,803 y 0,795). En el análisis cualitativo, los codificadores tienden a recortar entidades largas, mientras que los LLMs amplían los límites y presentan mayor frecuencia de alucinaciones. Asimismo, los codificadores procesan documentos en menos de 0,22 segundos, con una velocidad de inferencia entre 60× y 100× superior a la de los modelos generativos.

En conclusión, los codificadores constituyen la opción más adecuada cuando se dispone de datos de entrenamiento, dada su velocidad y precisión. Los modelos generativos representan una alternativa en escenarios con escasez de datos, al extraer una proporción considerable de entidades sin requerir entrenamiento previo.

Palabras Clave: Reconocimiento de Entidades Nombradas, Procesamiento del Lenguaje Natural Clínico, Modelos Codificadores, Grandes Modelos de Lenguaje, Afinamiento Supervisado, QLoRA, DisTEMIST, ProcTEMIST, PLN Biomédico en Español.

Abstract

Named Entity Recognition (NER) is a Natural Language Processing task that locates and classifies concepts within unstructured texts. Its application in the biomedical domain supports the automated extraction of clinical information, although the complexity of medical language introduces challenges. Historically, this field has been dominated by models based on the encoder component of the Transformer architecture, such as RoBERTa. The increasing adoption of generative Large Language Models (LLMs), based on the decoder component of that architecture, makes it necessary to compare both approaches in terms of performance and efficiency.

This Master's Thesis evaluates this question within the Spanish clinical domain using the DisTEMIST (diseases) and ProcTEMIST (procedures) corpora, built upon 1,000 real cases. Five encoders trained with supervised techniques are evaluated against six open-source LLMs and GPT-4.1-mini, a proprietary model from OpenAI. These models are assessed under both parameter-free strategies, including in-context learning with and without examples, and supervised fine-tuning with efficient techniques such as QLoRA. To ensure comparability with the original competitions, the same strict metric used in those shared tasks is applied, requiring the exact character-level position of each term to be identified.

Results show that encoders achieve the highest performance, with a strict F1 of 0.805 on ProcTEMIST and 0.797 on DisTEMIST. The best open-source model, Ministral-3-8B-Instruct, obtains similar results after QLoRA training (0.793 on both corpora), close to those of the commercial model GPT-4.1-mini (0.803 and 0.795). In the qualitative analysis, encoders tend to truncate long entities, whereas LLMs expand boundaries and show a higher frequency of hallucinations. Furthermore, encoders process documents in under 0.22 seconds, with inference speeds between 60× and 100× higher than generative models.

In conclusion, encoders represent the most suitable option when training data is available, given their speed and precision. Generative models constitute an alternative in low-data scenarios, extracting a considerable proportion of entities without requiring prior training.

Keywords: Named Entity Recognition, Clinical Natural Language Processing, Encoder Models, Large Language Models, Supervised Fine-Tuning, QLoRA, DisTEMIST, ProcTEMIST, Spanish Biomedical NLP.

Índice general

1	Introducción	1
1.1	Motivación y contexto del proyecto	1
1.2	Objetivos	2
1.3	Estructura del Documento	3
2	Marco Normativo y Ético	5
2.1	Marco Legal en el Tratamiento de Datos Clínicos	5
2.2	Cumplimiento Ético y Licenciamiento de los Corpus	6
2.3	Marco Regulatorio en Inteligencia Artificial	6
2.4	Justificación Ética de la Arquitectura Propuesta	7
3	Estado del Arte	8
3.1	El Procesamiento del Lenguaje Natural Clínico	8
3.1.1	La Tarea de Reconocimiento de Entidades Nombradas (NER)	8
3.2	Recursos y Corpus en el Dominio Biomédico	9
3.2.1	Contexto Internacional: Benchmarks de Referencia en Inglés	9
3.2.2	El Ecosistema en Español	10
3.3	Evolución de las Arquitecturas para NER	11
3.3.1	La Era Pre-Neuronal: Enfoques Simbólicos y Estadísticos	11
3.3.2	Aprendizaje Profundo Secuencial	12
3.3.3	El Paradigma Discriminativo Actual: Modelos Encoder	12
3.3.4	El Paradigma Generativo Emergente: Large Language Models	15
3.3.4.1	Estrategias de Adaptación: ICL y Fine-Tuning	15
3.3.4.2	Optimización Eficiente (PEFT y QLoRA)	15
3.3.4.3	Arquitecturas Decoder de Referencia	17
4	Metodología y Diseño Experimental	19
4.1	Entorno de Implementación	19
4.2	Preprocesamiento de Datos	19
4.2.1	Preparación para Codificadores	20
4.2.2	Preparación para Decodificadores	21
4.3	Implementación de Modelos Codificadores	21
4.3.1	Preparación de secuencias	21
4.3.2	Entrenamiento y validación	21
4.3.2.1	Discriminative fine-tuning	22
4.3.2.2	Evaluación con Sequeval	23
4.3.3	Ensamble e inferencia	23
4.4	Implementación de Modelos Decodificadores	24
4.4.1	Carga del modelo	24

4.4.2	Adaptadores LoRA	25
4.4.3	Construcción del dataset y diseño del prompt	25
4.4.4	Entrenamiento	26
4.4.5	Inferencia y recuperación de <i>offsets</i>	27
4.5	Métricas de Evaluación Comunes	27
4.5.1	Evaluación Estricta por Offsets Exactos	27
4.5.2	Evaluación por Solapamiento (IoU)	28
4.5.3	Análisis de Fronteras mediante Métrica Delta	28
5	Resultados y Discusión	29
5.1	Desempeño del Paradigma Discriminativo (Encoders)	29
5.1.1	Análisis Cuantitativo	29
5.1.2	Análisis Cualitativo de Errores	31
5.1.2.1	Errores de delimitación de fronteras	31
5.1.2.2	Falsos negativos: omisiones completas	33
5.1.2.3	Falsos positivos: detecciones sin solapamiento	33
5.1.3	Síntesis e implicaciones	34
5.2	Desempeño del Paradigma Generativo (Decoders)	35
5.2.1	Análisis Cuantitativo	35
5.2.2	Análisis Cualitativo de Errores en Decoders	37
5.2.2.1	Errores de delimitación de fronteras	38
5.2.2.2	Falsos negativos: omisiones completas	39
5.2.2.3	Falsos positivos: Detecciones sin solapamiento	39
5.2.3	Síntesis e implicaciones	40
5.3	Análisis Comparativo Global y Eficiencia Computacional	41
6	Conclusiones y Líneas de Trabajo Futuro	43
	Bibliografía	45
A	Anexo	51
A.1	Prompts para DisTEMIST (Enfermedades)	51
A.2	Prompts para ProcTEMIST (Procedimientos)	54

Índice de Figuras

3.1	Ejemplo de caso clínico anotado visualmente mediante la herramienta Brat (arriba) y su correspondiente representación tabular estructurada mediante <i>offsets</i> de caracteres (abajo). Fuente: [6].	9
3.2	Comparativa arquitectónica y de consumo de memoria entre el ajuste fino completo, LoRA y la aproximación QLoRA. Fuente: [68]	16
4.1	Comparativa entre <i>segeval</i> y la evaluación estricta por <i>offsets</i> sobre un ejemplo real. Fuente: Elaboración propia.	24
5.1	Rendimiento F1 de los ensambles frente al estado del arte y ganancia $\Delta F1$ aportada por el voto por mayoría (der.). Fuente: Elaboración propia.	31
5.2	Ablación sobre el tamaño máximo de chunk en Ministral-3-8B-Instruct (DisTEMIST). Cada punto corresponde a un experimento SFT completo con QLoRA. Fuente: Elaboración propia.	35
5.3	Gráfico de pendiente del rendimiento F1 de los decodificadores desde zero-shot hasta SFT. Izquierda (DisTEMIST): Umbral ganador F1 = 0,777. Derecha (ProcTEMIST): Umbral ganador F1 = 0,798. Fuente: Elaboración propia.	36
5.4	Diferencial de <i>recall</i> por longitud de span en DisTEMIST (izquierda) y ProcTEMIST (derecha). Discriminativo vs. Generativo. Fuente: Elaboración propia.	39

Índice de Tablas

3.1	Cronología, origen y temática de los principales corpus para BioNER en español. Fuente: Elaboración propia.	11
3.2	Comparativa de estadísticas entre DisTEMIST y ProcTEMIST sobre la base documental SPACCC. Fuente: Elaboración propia a partir de [6] y [7].	11
3.3	Comparativa de rendimiento (F1-score) de modelos Encoder. Fuente: Elaboración propia.	14
3.4	Comparativa unificada de rendimiento (F1 estricto) extraída de Obeidat et al. (2025) [11] y Keloth et al. (2024) [9]. Los valores de BC5CDR no son directamente comparables: Obeidat evalúa químicos y enfermedades conjuntamente, mientras que Keloth extrae únicamente químicos. Fuente: Elaboración propia.	18
5.1	Resultados cuantitativos de los modelos discriminativos (Encoders) bajo evaluación estricta por caracteres en los corpus DisTEMIST y ProcTEMIST. Fuente: Elaboración propia.	29
5.2	Estadísticos de precisión, recall y F1 en validación cruzada (media $\pm$ desviación estándar, mínimo y máximo de F1 de los modelos individuales del ensamble) y ganancia del ensamble respecto al mejor modelo individual. Fuente: Elaboración propia.	30
5.3	Errores de delimitación de fronteras: ejemplos de truncación y extensión por corpus (ensamble discriminativo). Fuente: Elaboración propia.	32
5.4	Ejemplos de omisiones completas (Falsos Negativos) clasificadas por corpus y origen del error. Fuente: Elaboración propia.	34
5.5	Ejemplos de falsos positivos: detecciones espurias sin solapamiento. Fuente: Elaboración propia.	34
5.6	Resultados cuantitativos de los modelos generativos (Decoders) en DisTEMIST. Se reporta el rendimiento previo (0-shot y 5-shot) y la ganancia tras el ajuste supervisado ($\Delta F1$). Fuente: Elaboración propia.	36
5.7	Resultados cuantitativos de los modelos generativos (Decoders) en ProcTEMIST. Se reporta el rendimiento previo (0-shot y 5-shot) y la ganancia tras el ajuste fino ($\Delta F1$). Fuente: Elaboración propia.	36

5.8	Errores de delimitación de fronteras en el paradigma generativo: ejemplos representativos de truncación y extensión por corpus. Fuente: Elaboración propia.	38
5.9	Composición global de los falsos negativos por categoría en ambos paradigmas, expresada como porcentaje sobre el total de errores de cada paradigma. Fuente: Elaboración propia.	39
5.10	Ejemplos de omisiones completas en el paradigma generativo clasificadas por tipología. Fuente: Elaboración propia.	40
5.11	Ejemplos de falsos positivos en el paradigma generativo. Fuente: Elaboración propia.	40
5.12	Comparativa global de F1 estricto y tiempo de inferencia por archivo en DisTEMIST y ProcTEMIST. En los encoders, el tiempo corresponde al de un único modelo del ensamble. Fuente: Elaboración propia. . . .	41

Capítulo 1

Introducción

Este capítulo introductorio comienza detallando la motivación que impulsa el estudio, centrada en un vacío de investigación en el NER biomédico en español. A continuación, se definen los objetivos específicos que guiarán el proyecto y, finalmente, se describe la estructura general de este documento.

1.1. Motivación y contexto del proyecto

En el dominio biomédico coexisten datos estructurados, típicamente exportados por instrumentos o máquinas, y un volumen masivo de información no estructurada, como notas clínicas redactadas por profesionales y literatura científica. La capacidad de transformar este texto libre en datos estructurados es crítica para la investigación y la toma de decisiones clínicas. En este contexto, el Reconocimiento de Entidades Nombradas (NER, por sus siglas en inglés) surge como una tarea fundamental del Procesamiento del Lenguaje Natural (PLN). Formalmente, el NER consiste en el proceso automático de identificar, delimitar y clasificar menciones de conceptos clave dentro de categorías predefinidas [1]. En el ámbito médico, esta tarea presenta desafíos únicos debido a la complejidad terminológica y la alta variabilidad léxica, donde un mismo concepto suele poseer múltiples sinónimos, además de la dificultad para establecer límites claros entre conceptos anidados [2]. Al trasladar este problema al español, la dificultad se agrava por la riqueza morfológica, la flexibilidad sintáctica y una brecha histórica de recursos anotados en comparación con el inglés.

Históricamente, los sistemas de NER evolucionaron desde enfoques basados en reglas y algoritmos estadísticos como los CRF, pasando por el modelo híbrido BiLSTM-CRF hasta las arquitecturas basadas en el *Transformer* [1, 2]. Estas últimas emplean mecanismos de atención pre-entrenados sobre corpus masivos y se dividen en tres familias según los bloques que utilizan y el mecanismo de atención que aplican: los *Encoders* (como BERT), que emplean atención bidireccional completa orientada a la comprensión; los *Encoder-Decoder* (como T5), diseñados para tareas de secuencia a secuencia; y los *Decoders* o Grandes Modelos de Lenguaje (LLMs) (como GPT o Llama), modelos autorregresivos especializados en generación y con una escala masiva de parámetros, que emplean atención enmascarada [3, 4].

En los últimos años, el estado del arte en NER ha permanecido dominado por los *Encoders*. Keraghel et al. [5] y Goyal et al. [2] coinciden en que estas arquitecturas

destacan por su capacidad natural para ajustarse a las métricas estrictas y a la rigidez posicional que exige la tarea. Esta tendencia se observa también de forma clara en el ecosistema hispanohablante, donde modelos generales y adaptaciones clínicas específicas ocupan los primeros puestos de competiciones como DisTEMIST y MedProcNER, lo que apunta a que estas arquitecturas se han consolidado como el estándar de referencia [6, 7].

No obstante, el panorama internacional está evolucionando con la integración de los *Decoders* y las estrategias de optimización descritas por Zhao et al. [3]. Inicialmente, las evaluaciones de estos grandes modelos generativos mediante aprendizaje en contexto (*In-Context Learning* o ICL, incluyendo *few-shot prompting*) indicaron que no alcanzan resultados del todo competitivos, mostrando inestabilidad y propensión a errores en los límites de las entidades frente a los codificadores tradicionales [8, 9]. Sin embargo, el Afinamiento Supervisado (SFT) parece alterar esta dinámica. Estudios recientes como el de Baroian [10] sugieren que, al aplicar SFT, los LLMs consiguen asimilar la exactitud estructural exigida por el NER, alcanzando un rendimiento competitivo capaz de superar a los *Encoders* tradicionales. Pese a este éxito, las barreras de privacidad de los datos hospitalarios y los altos costes recurrentes asociados a las API de modelos propietarios limitan drásticamente su aplicabilidad en entornos reales.

En respuesta a estas limitaciones, resulta imperativo explorar el potencial de los modelos de código abierto. En la literatura en inglés, Obeidat et al. [11] indicaron que, al aplicar SFT mediante técnicas de parametrización eficiente como QLoRA, modelos *Decoder* de tamaño contenido (como Llama-3 o Mistral) logran un rendimiento altamente competitivo frente a los mejores *Encoders* con una ventaja de entre el 2 % y el 8 % en F1-score. Frente a esta evidencia, se hace patente un vacío de investigación en el ecosistema hispanohablante: mientras en inglés la eficiencia de QLoRA permite entrenar modelos generativos para batir a las arquitecturas tradicionales, en español los codificadores siguen dominando el campo y las aproximaciones generativas se han restringido mayoritariamente a estrategias *few-shot* sin ajuste de parámetros [12].

Partiendo de estos antecedentes, este Trabajo Fin de Máster plantea la siguiente hipótesis:

¿Es replicable el rendimiento competitivo de los LLMs de código abierto con SFT frente a los Encoders tradicionales en el dominio biomédico en español?

El objetivo principal es evaluar si modelos generativos locales, optimizados eficientemente, pueden alcanzar un rendimiento superior en las competiciones DisTEMIST y MedProcNER, desplazando a las soluciones basadas en codificadores. Para ello, se realizará una comparativa que aborde no solo la precisión estricta en la extracción de entidades, sino también la viabilidad de estos modelos como una alternativa privada, eficiente y de alto rendimiento para el entorno clínico real.

1.2. Objetivos

Este trabajo persigue un objetivo principal que se desglosa en varios objetivos específicos.

El objetivo principal es:

- Realizar una evaluación comparativa del rendimiento y la eficiencia computacional entre el paradigma de los modelos codificadores (SOTA actual) y el paradigma emergente de los modelos decodificadores, analizando tanto sus capacidades inherentes (In-Context Learning) como su potencial tras el afinamiento supervisado, para la tarea de NER puro en el dominio biomédico en español.

Para alcanzar este objetivo principal, se establecen los siguientes objetivos específicos:

1. **Establecer la línea base (Baseline):** Replicar el estado del arte actual (SOTA) basado en modelos codificadores en los *benchmarks* DistEMIST y MedProcNER.
2. **Evaluar capacidades inherentes (Zero-shot y Few-shot):** Determinar el rendimiento base de los modelos generativos mediante estrategias de aprendizaje en contexto (ICL), para verificar si la ingeniería de instrucciones es suficiente o si se requiere un reentrenamiento.
3. **Implementar el paradigma de afinamiento:** Desarrollar un *pipeline* de afinamiento supervisado (SFT) utilizando técnicas de eficiencia de parámetros (PEFT) como QLoRA para los modelos decodificadores.
4. **Entrenar y evaluar los modelos LLM:** Aplicar este *pipeline* para afinar los modelos seleccionados y medir su mejora respecto a sus versiones base (Zero-shot/Few-shot).
5. **Comparar el rendimiento global:** Medir y comparar sistemáticamente la precisión (F1-score) entre los tres enfoques: Encoders (SOTA), Decoders base (ICL) y Decoders afinados (SFT).
6. **Analizar la eficiencia:** Evaluar y comparar el *trade-off* computacional, midiendo métricas clave como el tiempo de inferencia y el coste computacional de cada estrategia.
7. **Analizar los resultados:** Sintetizar los hallazgos para determinar qué paradigma ofrece la solución más efectiva y eficiente, discutiendo las ventajas y desventajas de cada enfoque para un entorno clínico real.

1.3. Estructura del Documento

El presente documento se organiza en los siguientes capítulos para abordar de manera sistemática los objetivos propuestos:

- **Capítulo 1. Introducción:** Presenta el contexto del problema, la motivación del proyecto identificando el vacío de investigación actual, los objetivos a cumplir y la estructura de este documento.
- **Capítulo 2. Marco Normativo y Ético:** Establece las bases legales de protección de datos (RGPD y LOPD-GDD) y valida el cumplimiento ético y licenciamiento de los corpus DistEMIST y MedProcNER. Asimismo, analiza los riesgos de los LLMs en el ámbito sanitario, como la privacidad y las alucinaciones, justificando el uso de modelos locales bajo la Ley de IA de la Unión Europea.
- **Capítulo 3. Estado del Arte:** Revisa en profundidad los conceptos teóricos y los trabajos previos relevantes. Se describen los dos paradigmas computacionales

(codificadores vs. decodificadores), las técnicas de afinamiento y los *benchmarks* de referencia.

- **Capítulo 4. Metodología y Diseño Experimental:** Detalla cómo se implementa el proyecto. Se describen la arquitectura de los modelos seleccionados, el diseño del *pipeline* de SFT y las métricas de evaluación.
- **Capítulo 5. Resultados y Discusión:** Presenta tanto los resultados cuantitativos como el análisis cualitativo de los experimentos. Se comparan las métricas de F1-score y velocidad de inferencia de todos los modelos y se discuten los hallazgos, analizando el *trade-off* entre rendimiento y eficiencia.
- **Capítulo 6. Conclusiones y Trabajo Futuro:** Resume los hallazgos clave, responde a la pregunta de investigación planteada en la motivación, enumera las limitaciones del estudio y propone líneas de investigación futuras.

Capítulo 2

Marco Normativo y Ético

Este capítulo establece las bases legales del proyecto: se analiza primero la legislación sobre protección de datos personales, se detalla el cumplimiento ético de los conjuntos de datos seleccionados (DisTEMIST y ProcTEMIST), se estudia la regulación sobre Inteligencia Artificial en Europa y España, y se concluye con la justificación ética de la arquitectura propuesta.

2.1. Marco Legal en el Tratamiento de Datos Clínicos

La protección de la información sanitaria constituye uno de los pilares fundamentales de la bioética moderna. En este contexto, el marco jurídico que garantiza el derecho fundamental a la privacidad frente al tratamiento automatizado de datos está establecido principalmente por el Reglamento (UE) 2016/679 (RGPD) [13], de aplicación directa en toda Europa, y la Ley Orgánica 3/2018 (LOPD-GDD) [14] en el ámbito nacional. El RGPD clasifica los datos de salud como «categorías especiales» (art. 9) y prohíbe su tratamiento con carácter general, salvo que concurra alguna de las excepciones del artículo 9.2, entre ellas la investigación científica con las garantías adecuadas previstas en el artículo 89.

A efectos de este marco, resulta esencial distinguir entre seudonimización y anonimización. La seudonimización (art. 4.5 RGPD) consiste en tratar los datos de forma que no puedan atribuirse a un interesado sin recurrir a información adicional conservada por separado; reduce el riesgo, pero los datos siguen siendo personales y el RGPD continúa siendo de aplicación. La anonimización, en cambio, implica una ruptura irreversible entre los datos y cualquier persona identificable; según la AEPD y el Considerando 26 del RGPD, solo cuando no existe capacidad material de reidentificación el conjunto de datos queda fuera del ámbito del Reglamento. Los corpus empleados en este trabajo se derivan de literatura científica ya publicada y han sido sometidos a los procesos de anonimización exigidos por la Ley 14/2007 de Investigación Biomédica [15], por lo que no constituyen datos personales y su uso no requiere base jurídica de tratamiento bajo el RGPD.

En un hipotético despliegue en entorno clínico real, donde el sistema procesase datos de pacientes identificables, sería necesario identificar una base jurídica válida conforme al artículo 6 del RGPD y una excepción adicional del artículo 9.2. Las bases más plausibles serían el interés público o la investigación científica (arts. 6.1.e y 9.2.j),

condicionadas a la adopción de garantías como la seudonimización y medidas técnicas de control de acceso, al amparo de la Disposición adicional decimoséptima de la LOPD-GDD.

2.2. Cumplimiento Ético y Licenciamiento de los Corpus

Al amparo del marco legal descrito, este trabajo utiliza dos corpus de referencia: DisTEMIST [6] y ProcTEMIST [7]. Ambos conjuntos se fundamentan en el Spanish Clinical Case Corpus (SPACCC) [16], una colección de 1.000 documentos textuales seleccionados manualmente a partir de la biblioteca SciELO. La elección de esta fuente garantiza la integridad ética de los datos, dado que SciELO impone una estricta «Guía de Buenas Prácticas» [17]. El cumplimiento normativo se sustenta en dos pilares:

- **Garantía de origen y vigilancia ética:** A diferencia de las historias clínicas crudas, estos corpus se derivan de literatura científica ya publicada. Según la normativa de SciELO, alineada con los estándares del COPE [18] y el ICMJE [19], es requisito indispensable que los autores presenten el dictamen del comité de ética y el consentimiento informado. Por tanto, los datos ya fueron sometidos a los procesos de anonimización exigidos por la Ley 14/2007 [15].
- **Licenciamiento abierto:** El equipo del Barcelona Supercomputing Center (BSC-CNS) liberó el corpus resultante bajo una licencia Creative Commons Attribution 4.0 International (CC-BY 4.0) [20]. Esta licencia otorga explícitamente libertad para compartir y adaptar el material, ofreciendo la cobertura necesaria para realizar el ajuste fino propuesto.

La única obligación impuesta por esta licencia es la de Atribución, requisito satisfecho mediante las referencias en este documento.

2.3. Marco Regulatorio en Inteligencia Artificial

La evolución tecnológica de la IA ha superado los marcos éticos tradicionales, consolidándose en una estructura normativa obligatoria encabezada por el Reglamento (UE) 2024/1689 [21], el cual establece un enfoque basado en el riesgo que condiciona el uso de modelos de lenguaje en el ámbito clínico. Dentro de esta normativa, resultan fundamentales dos categorías que afectan a este proyecto:

- **Sistemas de Alto Riesgo:** En su estado actual, este TFM no constituye un sistema de alto riesgo: opera sobre datos completamente anonimizados en un entorno académico de investigación, sin producir decisiones que afecten directamente a pacientes. No obstante, si el sistema fuese desplegado en un entorno clínico real, pasaría a clasificarse previsiblemente bajo el Anexo III del Reglamento, activando las obligaciones de los artículos 9 a 15, entre las que destacan la gestión de riesgos durante todo el ciclo de vida, la gobernanza de datos de entrenamiento, el registro automático de operaciones, la supervisión humana efectiva y la superación de una evaluación de conformidad previa a la puesta en servicio conforme al artículo 43.
- **Modelos de IA de uso general (GPAI):** El Reglamento, en su artículo 53, establece obligaciones directas para los proveedores de modelos GPAI, entre ellas documentación técnica, cumplimiento de la normativa de propiedad intelectual y

publicación de un resumen de los datos de entrenamiento. Modelos como Llama-3 o Mistral, en tanto que GPAI, ya están sujetos a estas obligaciones por parte de sus proveedores originales (Meta y Mistral AI, respectivamente). Al realizar un Afinamiento Supervisado para NER biomédico, el desarrollador asume adicionalmente la responsabilidad de la conformidad técnica de la aplicación específica resultante, debiendo documentar cómo el proceso de especialización afecta al comportamiento del modelo.

La arquitectura propuesta se alinea con estas exigencias. El despliegue mediante modelos locales garantiza el control sobre la gobernanza de datos y la documentación técnica requerida, cumpliendo con el principio de privacidad por diseño, y la naturaleza extractiva de la tarea NER mitiga los riesgos de alucinaciones propios de los modelos generativos. España refuerza este marco mediante el Real Decreto 817/2023 [22], que regula el sandbox de IA como entorno de pruebas controlado, y encomienda la supervisión institucional a la Agencia Española de Supervisión de Inteligencia Artificial (AESIA), creada por el Real Decreto 729/2023 [23].

2.4. Justificación Ética de la Arquitectura Propuesta

La elección de la arquitectura tecnológica plantea desafíos éticos propios que este trabajo aborda priorizando el uso de modelos locales frente a servicios en la nube, con el fin de mitigar riesgos de privacidad y seguridad del paciente inherentes a la tarea de NER biomédico.

El uso de modelos accesibles mediante API externas conlleva la transferencia de información clínica a servidores de terceros. Carlini et al. [24] sugieren que los modelos de lenguaje a gran escala pueden memorizar datos de entrenamiento y resultar vulnerables a ataques de extracción, lo que en un contexto de salud real podría suponer un riesgo inaceptable de reidentificación de pacientes. La arquitectura on-premise propuesta favorece la soberanía del dato y el principio de *Privacy by Design*, de forma que el flujo de información sensible permanezca bajo control institucional.

Por otro lado, la naturaleza de caja negra de los modelos profundos dificulta la transparencia, imperativa en medicina según Tjoa y Guan [25] para evitar decisiones basadas en patrones engañosos. Este riesgo se agrava por las alucinaciones generativas, definidas por Ji et al. [26] como contenido fluido pero incorrecto. Nuestro enfoque mitiga estas dificultades contrastando las capacidades base (*Zero-shot/Few-shot*) frente a la especialización por Afinamiento Supervisado (SFT). Al restringir el decodificador a una tarea extractiva cerrada, esta última técnica reduce la incertidumbre y prioriza la fidelidad a la fuente, transformando la herramienta generativa en un sistema de apoyo secundario de alta fiabilidad clínica bajo supervisión humana.

Capítulo 3

Estado del Arte

Este capítulo establece el marco teórico del proyecto. Se define la tarea de NER clínico y sus retos específicos en español, se catalogan los corpus de referencia del ecosistema hispanohablante y se analiza la evolución de las arquitecturas, desde los enfoques simbólicos hasta los modelos generativos, incluyendo las estrategias de adaptación que fundamentan la metodología experimental propuesta.

3.1. El Procesamiento del Lenguaje Natural Clínico

La digitalización sanitaria ha generado un volumen masivo de texto libre en las Historias Clínicas Electrónicas (HCE), bloqueando su análisis automático para vigilancia epidemiológica o medicina de precisión [27, 2]. El Procesamiento del Lenguaje Natural (PLN) clínico busca estructurar estas narrativas telegráficas, redactadas bajo presión asistencial y repletas de errores, jerga y abreviaturas ambiguas [28]. El traslado de este problema al español añade una dificultad estructural: siendo el cuarto idioma más hablado (559 millones de hablantes), apenas dispone de 2,3 modelos de PLN por millón de hablantes frente a los 11,3 del inglés [28, 29], lo que sitúa la escasez de recursos anotados entre los principales obstáculos para el avance del campo. Es precisamente sobre esta carencia sobre la que se articula la tarea central de este trabajo.

3.1.1. La Tarea de Reconocimiento de Entidades Nombradas (NER)

Impulsado por las arquitecturas *Transformer*, el Reconocimiento de Entidades Nombradas (NER) ha experimentado una explosión académica [5] como método estándar para extraer conocimiento de estos textos. Formalmente, dada una secuencia $x = (x_1, \dots, x_n)$, el objetivo es predecir las etiquetas $y = (y_1, \dots, y_n)$ que maximicen $P(y|x)$ [1]. El formato canónico de los corpus anota cada mención mediante sus caracteres de inicio y fin (*offsets*) dentro del documento original, tal y como ilustra la Figura 3.1.

Canotipo retiniano normal 40 XX.

El diagnóstico por ecografía prenatal de esta niña muestra **ENFERMEDAD** agenesia del cuerpo calloso y **ENFERMEDAD** riñón derecho displásico multiquistico.

En el sistema nervioso central presenta un quiste de plexos coroideos y un **ENFERMEDAD** quiste en la región interhemisférica profunda.

En el examen de resonancia magnética nuclear, no se detectan anomalías de la migración neuronal. Los registros electroencefalográficos (EEG) fueron normales. Los estudios cognitivos muestran un cociente de desarrollo psicomotor normal. La exploración del fondo de ojo muestra una apariencia prácticamente normal del fondo de ojo derecho, con una papila óptica normal, dos pequeñas lagunas coriorretinianas hipopigmentadas y ausencia de **ENFERMEDAD** afectación macular.

Sin embargo, observamos en el fondo de ojo izquierdo una **ENFERMEDAD** malformación colobomatosa del nervio óptico y

doc1	T1	ENFERMEDAD	209	236	agenesia del cuerpo calloso	5102002	EXACT		
doc1	T2	ENFERMEDAD	239	277	riñón derecho displásico multiquistico	82525005	EXACT	NARROW	
doc1	T3	ENFERMEDAD	322	348	quiste de plexos coroideos	230790004	EXACT		
doc1	T4	ENFERMEDAD	354	399	quiste en la región interhemisférica profunda	40720005	EXACT	NARROW	
doc1	T5	ENFERMEDAD	914	957	malformación colobomatosa del nervio óptico	77157004	EXACT	NARROW	
doc1	T6	ENFERMEDAD	960	984	lagunas coriorretinianas	302893000	NARROW		
doc1	T7	ENFERMEDAD	462	496	anomalías de la migración neuronal	253146009	EXACT		
doc1	T8	ENFERMEDAD	837	855	afectación macular	312999006	EXACT		
doc1	T9	ENFERMEDAD	1005	1023	afectación macular	312999006	EXACT		

Figura 3.1: Ejemplo de caso clínico anotado visualmente mediante la herramienta Brat (arriba) y su correspondiente representación tabular estructurada mediante *offsets* de caracteres (abajo). Fuente: [6].

Los distintos paradigmas de modelado resuelven esta tarea de forma diferente. Los modelos *encoder* la reformulan como un problema de etiquetado de secuencias, convirtiendo los *offsets* del corpus en esquemas de etiquetado como BIO (*Beginning, Inside, Outside*) o su extensión BIOES: por ejemplo, en la frase “padece cáncer de pulmón”, “padece” se codifica como O (fuera de entidad), mientras que el diagnóstico se etiqueta como B-Enf, I-Enf, I-Enf ilustrando cómo BIO delimita el inicio y la continuación de una entidad [28, 1]. Los modelos *decoder*, en cambio, abordan la tarea desde un marco generativo, produciendo directamente las menciones mediante instrucciones; el tratamiento específico de cada paradigma se detalla en la Sección 4.2.

La calidad extractiva se mide comparando las menciones predichas con las del *gold standard*, pudiendo emplearse criterios parciales que aceptan solapamientos o evaluación estricta por *offsets* exactos, que exige coincidencia exacta de límites y tipo de entidad; este último es el criterio adoptado en el presente estudio y se formaliza en la Sección 4.5. En el dominio biomédico esta precisión resulta especialmente exigente, ya que los modelos deben capturar entidades anidadas [30] y respetar la dimensión veritativa de los hallazgos, distinguiendo afirmaciones de negaciones o especulaciones [28]. El desarrollo de sistemas capaces de afrontar estos retos depende, en última instancia, de la disponibilidad de corpus anotados, cuyo ecosistema en español se examina a continuación.

3.2. Recursos y Corpus en el Dominio Biomédico

El desarrollo de sistemas de NER depende de corpus anotados de calidad; a continuación se revisan los recursos del dominio biomédico más relevantes, desde los benchmarks internacionales en inglés hasta el ecosistema en español que fundamenta la experimentación de este trabajo.

3.2.1. Contexto Internacional: Benchmarks de Referencia en Inglés

La validación histórica del NER biomédico se ha consolidado en torno a tres fuentes. La literatura científica (PubMed) sentó las bases teóricas iniciales mediante corpus

como JNLPBA, BC5CDR o ChemProt para la extracción de entidades simples [31], evolucionando recientemente hacia el modelado de relaciones complejas en texto completo con BioRED [32]. Como contrapunto práctico, los desafíos i2b2/n2c2, contruidos sobre la masiva base de datos de cuidados intensivos MIMIC, definieron el estándar para el Registro Clínico Electrónico (EHR), obligando a los algoritmos a lidiar con la sintaxis telegráfica del entorno hospitalario real [33]. Finalmente, las restricciones de privacidad han propiciado la adopción de redes sociales (como Reddit o Twitter) como un *proxy* accesible para estudiar el lenguaje de salud de los pacientes, validando su utilidad clínica tanto en tareas de extracción [34] como en la detección temprana del Trastorno del Espectro Autista [35].

3.2.2. El Ecosistema en Español

La escasez de recursos en español se ha mitigado mediante el Plan de Impulso de las Tecnologías del Lenguaje (Plan TL), que fomentó *shared tasks* articuladas en IberLEF, BioASQ y BioCreative. Siguiendo la revisión de García-Subies et al. [28], los recursos se dividen en dos categorías funcionales.

Los *corpus no anotados* son colecciones masivas de texto clínico crudo que sirven para el pre-entrenamiento de modelos de lenguaje y actúan como materia prima sobre la que se construyen posteriormente los datasets etiquetados. El recurso fundacional es SPACCC [16] (400.000 tokens de SciELO), ampliado a escala europea por E3C [36]. Su evolución más reciente es ClinText-SP [37], que consolida 26 millones de tokens clínicos integrando múltiples fuentes médicas.

Los *corpus anotados*, etiquetados manualmente por expertos, constituyen el núcleo de las competiciones de evaluación y abarcan tres orígenes principales: registros hospitalarios (EHRs), literatura médica de acceso abierto y fuentes heterogéneas como redes sociales o ensayos clínicos. El eje central de la literatura médica son los 1.000 textos SPACCC, sobre los que la familia TEMIST ha construido capas progresivas de anotación: síntomas (SympTEMIST [38]), patologías (DisTEMIST [6]), procedimientos (ProcTEMIST [7]) y medicamentos (DrugTEMIST [39]). La Tabla 3.1 cataloga la progresión cronológica completa del ecosistema.

Para la validación experimental se han seleccionado DisTEMIST y ProcTEMIST (resaltados en gris), limitándonos exclusivamente a la sub-tarea de NER. DisTEMIST [6] es el primer recurso estructurado para detección de patologías en múltiples especialidades, con más de 10.000 anotaciones bajo la categoría ENFERMEDAD. ProcTEMIST [7], aunque comparte los mismos 1.000 textos base, presenta una mayor densidad de anotación (14.684 anotaciones) al agrupar una amplia heterogeneidad de intervenciones, desde pruebas diagnósticas hasta cirugías complejas, bajo la etiqueta única PROCEDIMIENTO. Esta base documental compartida permite aislar la capacidad del modelo para gestionar distintas complejidades semánticas manteniendo constante el dominio lingüístico, favoreciendo una evaluación rigurosa y reproducible. La Tabla 3.2 detalla las estadísticas comparativas de ambos recursos.

Estado del Arte

Dataset	Año	Marco	Origen	Entidad / Tema	Ref.
IULA-SCRC	2017	-	Hospitales (EHRs)	Diagnósticos y procesos	[40]
BARR2	2018	IberEval	Literatura Médica	Abreviaturas médicas	[41]
SPACCC	2018	-	Literatura Médica	Corpus base clínico	[16]
MEDDOCAN	2019	IberLEF	Literatura Médica	Anonimización (PHI)	[42]
PharmaCoNER	2019	IberLEF	Literatura Médica	Fármacos y proteínas	[43]
CANTEMIST	2020	IberLEF	Literatura Médica	Morfología tumoral	[44]
CodiEsp	2020	CLEF	Literatura Médica	Codificación CIE-10	[45]
NUBes	2020	-	Hospitales (EHRs)	Negación e incertidumbre	[46]
CWLC	2020	-	Hospitales (EHRs)	Listas de espera	[47]
eHealthKD	2021	IberLEF	Fuentes Diversas	Entidades y relaciones	[48]
MEDDOPROF	2021	IberLEF	Literatura Médica	Profesiones sanitarias	[49]
CT-EBM-SP	2021	-	Fuentes Diversas	Entidades clínicas múltiples	[50]
SocialDisNER	2022	SMM4H	Fuentes Diversas	Enfermedades	[51]
LivingNER	2022	IberLEF	Literatura Médica	Especies y patógenos	[52]
DisTEMIST	2022	BioASQ	Literatura Médica	Enfermedades	[6]
SympTEMIST	2023	BioCreative	Literatura Médica	Síntomas y signos	[38]
ProcTEMIST	2023	BioASQ	Literatura Médica	Procedimientos clínicos	[7]
MEDDOPLACE	2023	IberLEF	Literatura Médica	Ubicaciones clínicas	[53]
DrugTEMIST	2024	BioASQ	Literatura Médica	Medicamentos	[39]
CardioCCC	2024	BioASQ	Literatura Médica	Cardiología	[39]

Cuadro 3.1: Cronología, origen y temática de los principales corpus para BioNER en español. Fuente: Elaboración propia.

Dataset	Split	Docs	Frases	Tokens	Anot.
DisTEMIST	Train	750	12.499	305.166	8.066
	Test	250	4.179	101.152	2.599
	Total	1.000	16.678	406.318	10.665
ProcTEMIST	Train	750	-	-	-
	Test	250	-	-	-
	Total	1.000	16.678	350.764	14.684

Cuadro 3.2: Comparativa de estadísticas entre DisTEMIST y ProcTEMIST sobre la base documental SPACCC. Fuente: Elaboración propia a partir de [6] y [7].

3.3. Evolución de las Arquitecturas para NER

A continuación se analiza la evolución cronológica de las arquitecturas de NER, desde los sistemas basados en reglas hasta el actual dominio de las redes neuronales profundas.

3.3.1. La Era Pre-Neuronal: Enfoques Simbólicos y Estadísticos

Dominantes hasta finales de los 90, los métodos basados en conocimiento priorizan reglas y diccionarios sobre datos de entrenamiento. Aunque precisos en dominios definidos, su rigidez conlleva bajo *recall*, escasa transferibilidad y altos costes de mantenimiento, limitando su uso actual a validación o escenarios con pocos datos [5].

La transición al aprendizaje supervisado introdujo modelos como los HMM, eficaces

pero limitados por estrictas asunciones de independencia. Como alternativa discriminativa surgió MaxEnt, capaz de integrar características solapadas pero afectado por el sesgo de etiqueta. La convergencia llegó con los Campos Aleatorios Condicionales (CRF), que resuelven dicho sesgo mediante normalización global y cuya capacidad para incorporar morfología arbitraria y dependencias los consolidó como el estándar predominante antes de la era neuronal [5].

Keraghel et al. [5] agrupan estos enfoques (HMM, CRF, SVM) bajo la “ingeniería de características”. Su dependencia de características artesanales costosas y frágiles, sumada a la dificultad para modelar dependencias de largo alcance y entidades anidadas, marcó su techo de rendimiento e impulsó el cambio hacia el aprendizaje profundo.

3.3.2. Aprendizaje Profundo Secuencial

El aprendizaje profundo sustituyó la codificación dispersa One-Hot por embeddings densos. Arquitecturas como Word2Vec y GloVe codifican semántica mediante proximidad geométrica, pero su tratamiento atómico resulta ineficaz ante terminología biomédica no vista (OOV). Esta limitación se resolvió con *Character* y *Subword Embeddings* (como fastText), que descomponen la morfología interna para inferir representaciones de términos complejos [1].

Para modelar la secuencia, las RNN superaron las ventanas fijas al mantener memoria histórica, aunque su problema de desvanecimiento del gradiente en textos largos llevó a las LSTM. El estándar en NER se consolidó con la variante BiLSTM-CRF: la BiLSTM procesa el contexto en ambas direcciones, mientras el CRF realiza una decodificación conjunta que garantiza la coherencia entre etiquetas, evitando secuencias inválidas como I-Enfermedad tras O [1, 5].

Sin embargo, como explican Vaswani et al. [54], el procesamiento paso a paso impide la paralelización del entrenamiento, infrautilizando las GPUs modernas. Además, estas arquitecturas tienden a ser superadas por los Transformers al capturar dependencias de largo alcance con mayor eficiencia [1], motivando el cambio de paradigma.

3.3.3. El Paradigma Discriminativo Actual: Modelos Encoder

La arquitectura *Transformer* [54] introdujo tres mecanismos de atención: *self-attention* bidireccional en el encoder, *masked self-attention* causal en el decoder y *cross-attention* para conectar ambos componentes. BERT [55] explotó exclusivamente el encoder mediante el Modelado de Lenguaje Enmascarado (MLM), consolidando el paradigma de pre-entrenamiento y ajuste fino. Sobre esta base, RoBERTa [56] optimizó el aprendizaje eliminando tareas redundantes y aplicando enmascaramiento dinámico.

La flexibilidad de estas arquitecturas radica en su capacidad de entrenamiento continuo a través del objetivo de MLM. Este aprendizaje puede iniciarse desde cero sobre textos clínicos masivos para crear modelos nativos como *bsc-bio-ehr-es* [57]. Alternativamente, es posible tomar modelos generalistas y refinarlos mediante exposición continua al idioma (LAPT, como *RigoBERTa 2.0* [28]) o al vocabulario específico del dominio médico (DAPT, como *RigoBERTa Clinical* [37]). En todas estas fases de pre-entrenamiento y adaptación, el *encoder* aprende a generar un vector de representación contextualizado para cada token de la secuencia.

Para transferir este conocimiento a tareas como por ejemplo el NER, la cabeza de

predicción de palabras ocultas se sustituye por una capa lineal que proyecta el vector contextual de cada token hacia el esquema de etiquetado BIO. Una función *Softmax* transforma de manera directa esta proyección en una distribución de probabilidad, asignando a cada palabra la categoría clínica con mayor probabilidad. Este enfoque lineal token a token constituye el principio metodológico de nuestra investigación para realizar el ajuste fino sobre los conjuntos de datos DisTEMIST y ProcTEMIST. Esta estrategia directa resulta plenamente efectiva para alcanzar el estado del arte, tal como sugiere el resultado de la arquitectura ganadora en DisTEMIST [58], lo que permite prescindir de mecanismos de decodificación estructurada más complejos como *Masked CRF* [59] o *Multi-head CRF* [60].

Por otro lado, el *Ensemble Learning* se establece como una estrategia complementaria decisiva en el diseño de este trabajo. Esta técnica, basada en la agregación de predicciones de múltiples modelos para mitigar la varianza y mejorar la robustez general, ha mostrado su eficacia en competiciones de NER biomédico, contribuyendo a alcanzar el primer puesto tanto en ProcTEMIST [59] como en MultiCardioNER [60].

A continuación, se describen los modelos que definen el estado del arte y su rendimiento comparativo (Tabla 3.3).

Modelos de Dominio Clínico

bsc-bio-ehr-es (roberta-base-biomedical-clinical-es) (Monolingüe). Presentado por Carrino et al. [57], este modelo basado en RoBERTa constituye el estándar para el dominio clínico en español. Fue entrenado desde cero con un corpus híbrido que combina 1.100 millones de tokens biomédicos con 95 millones de tokens extraídos de registros de hospitales reales (EHR), lo que le permite internalizar la sintaxis clínica práctica. Fue la base del equipo ganador en DisTEMIST (F1 0,777) [58] y constituyó uno de los dos modelos del *ensemble* ganador en la competición ProcTEMIST [59]. Licencia Apache 2.0¹.

roberta-es-clinical-trials-ner (Monolingüe). Especialización del anterior mediante ajuste fino sobre ensayos clínicos (corpus CT-EBM-SP) [50]. Su rendimiento es notable en tareas de extracción de procedimientos: co-fundamentó el sistema ganador de ProcTEMIST (F1 0,798) operando en *ensemble* con el modelo base anterior y capas *Masked CRF* [59]. Recientemente, ha vuelto a destacar en el sistema ganador de MultiCardioNER (2024) bajo una arquitectura *Multi-head CRF* [60]. Licencia CC BY-NC 4.0².

Modelos de Dominio General y Otras Arquitecturas

xlm-roberta-large (Multilingüe). Modelo masivo entrenado con 2,5 TB de datos en 100 idiomas [61]. En DisTEMIST alcanzó un F1-score de 0,817 (evaluado con *segeval*, véase la nota metodológica posterior), lo que apunta a que la escala de las representaciones multilingües puede prevalecer sobre la adaptación específica al dominio [28]. Licencia MIT³.

RigoBERTa 2.0 y Clinical (Monolingües). Desarrollado por el IIC [62], RigoBERTa 2.0 refina la arquitectura XLM-RoBERTa-Large mediante pre-entrenamiento

¹Disponible en: <https://huggingface.co/PlanTL-GOB-ES/bsc-bio-ehr-es>

²Disponible en: <https://huggingface.co/lcampillos/roberta-es-clinical-trials-ner>

³Disponible en: <https://huggingface.co/FacebookAI/xlm-roberta-large>

3.3. Evolución de las Arquitecturas para NER

adaptativo en un corpus de español curado, alcanzando un F1 de 0,832 en DisTEMIST [28]. Su evolución, RigoBERTa Clinical, añade adaptación de dominio sobre ClinText-SP (26M de tokens), elevando el rendimiento a 0,833 y superando a la versión base en 10 de 11 benchmarks [37]. Cabe señalar que ClinText-SP incorpora los textos SPACCC, que constituyen la base documental de DisTEMIST y ProcTEMIST. Ambas puntuaciones se evalúan exclusivamente con *segeval*. Tienen licencia Non-Commercial⁴.

La Tabla 3.3 sintetiza otras líneas base relevantes. Entre los modelos monolingües destacan MarIA y BETO. En el ámbito multilingüe, el ecosistema se amplía con mDeBERTaV3, longformer-bne-es (optimizado para secuencias largas) y CLIN-X-ES, que logra superar el estado del arte en Cantemist y PharmaCoNER [63, 28, 64]. Por otro lado, los enfoques de transferencia desde el inglés como BioM-BERT-Large no resultan competitivos frente a los nativos [65], mientras que la familia Galén explora el pre-entrenamiento en oncología [28].

Al revisar la Tabla 3.3, conviene precisar que los resultados de los modelos multilingües y la familia RigoBERTa [28, 37] se evalúan mediante *segeval*, que opera sobre secuencias de etiquetas BIO sin reconstruir los *offsets* originales; el resto utiliza un criterio estricto por caracteres que exige coincidencia exacta con el gold standard. Ambas métricas no son directamente comparables en cifras absolutas, diferencia que se explica en detalle en la Sección 4.3.2.2 y se ilustra en la Figura 4.1. Los resultados en negrita representan las mejores puntuaciones bajo criterio estricto.

Modelo	Arquitectura	Parámetros	F1 DisTEMIST	F1 ProcTEMIST
Modelos de Dominio Clínico				
RigoBERTa Clinical	RigoBERTa 2	~560M	0,833 [37]	-
CLIN-X-ES	XLNet-RoBERTa-L	~560M	0,805 [66]	0,698 [65]
roberta-es-clinical-trials	RoBERTa-base	~125M	-	0,798 [7]
bsc-bio-ehr-es	RoBERTa-base	~125M	0,777 [6]	0,765 [64]
XLNet-R-Galén	XLNet-RoBERTa	~278M	0,759 [28]	-
Modelos Generalistas y Multilingües				
RigoBERTa 2.0	XLNet-RoBERTa-L	~560M	0,832 [28]	-
XLNet-RoBERTa-Large	XLNet-RoBERTa	~560M	0,817 [28]	0,779 [64]
mDeBERTaV3	DeBERTa	~278M	0,808 [28]	-
BETO	BERT-base	~110M	0,801 [28]	-
MarIA (Large)	RoBERTa-large	~355M	0,793 [28]	-
longformer-bne-es	Longformer	~149M	-	0,753 [64]

Cuadro 3.3: Comparativa de rendimiento (F1-score) de modelos Encoder. Fuente: Elaboración propia.

Para la fase experimental se han seleccionado los cinco modelos descritos anteriormente con el objetivo de aislar el impacto del pre-entrenamiento de dominio: XLNet-RoBERTa-Large y RigoBERTa 2.0 como líneas base generalistas, y bsc-bio-ehr-es, roberta-es-clinical-trials y RigoBERTa Clinical como referencias clínicas, siendo estas dos últimas versiones comparables por compartir arquitectura base (XLNet-RoBERTa-Large), lo que permite aislar el efecto del pre-entrenamiento en textos clínicos.

⁴Disponibles en: <https://huggingface.co/IIC/RigoBERTa-2.0> y <https://huggingface.co/IIC/RigoBERTa-Clinical>

3.3.4. El Paradigma Generativo Emergente: Large Language Models

Frente al *self-attention* bidireccional del encoder, los modelos decodificadores emplean *masked self-attention* causal: cada token solo puede atender a los anteriores, lo que impone una generación autorregresiva y una inferencia inherentemente secuencial y, por tanto, más lenta [11]. Su ventaja reside en la escala: al aumentar masivamente los parámetros emergen capacidades no presentes en modelos menores, permitiéndoles abordar tareas para las que no fueron diseñados explícitamente, como la traducción o el NER [3], reduciendo la dependencia de arquitecturas y datos anotados específicos. A diferencia del encoder, que requiere una cabeza de clasificación por tarea, el decoder reformula el NER como generación de texto: dado un *prompt* con el fragmento clínico, predice iterativamente los tokens que conforman cada mención, sin modificar su arquitectura base. La ejecución práctica se materializa a través de dos grandes estrategias: el Aprendizaje en Contexto (ICL) y el Afinamiento Supervisado (SFT).

3.3.4.1. Estrategias de Adaptación: ICL y Fine-Tuning

La adaptación mediante Aprendizaje en Contexto (ICL), en configuraciones *zero-shot* o *few-shot*, opera sin alterar los parámetros del modelo [3]. Aunque resulta versátil, la predisposición de los LLMs a la generación libre choca con la exactitud posicional exigida por el NER [10, 9]. Bajo ICL se producen continuos errores de límites (*boundary errors*) al capturar un exceso de contexto clínico o alterar partículas [4, 8]; la brecha entre F1 parcial y estricto lo cuantifica: GPT-4 en *five-shot* acumula hasta 27,8 puntos de diferencia entre ambas métricas, frente a los 7,1 de media en modelos con afinamiento supervisado [9, 8]. La viabilidad de mitigar esto con instrucciones complejas presenta distintos puntos de vista: aunque inyectar guías médicas exhaustivas mejora la extracción [8], otros estudios indican que un *prompt* simple podría superar a uno complejo en un 3 % de rendimiento [10]. Independientemente de la configuración, el ICL rara vez logra batir a los codificadores tradicionales y, según la literatura revisada, no logra superar los resultados del afinamiento supervisado [8].

Para superar esta barrera, el Afinamiento Supervisado (SFT) actualiza los pesos de la red garantizando el seguimiento estricto de comandos y formatos mediante entropía cruzada sobre los tokens de respuesta, comparando la distribución del modelo con la ideal que asigna probabilidad 1 al token correcto [3]. La literatura sugiere que el SFT tiende a superar a las variantes de ICL analizadas al reducir la inestabilidad generativa y ajustarse a la exactitud posicional que exige el NER, permitiendo al decodificador interiorizar el concepto médico en sus parámetros [4, 10, 9].

3.3.4.2. Optimización Eficiente (PEFT y QLoRA)

Para mitigar los prohibitivos costes del ajuste fino completo, que ha exigido hasta cuatro GPUs A100 de 80 GB para afinar modelos de 7B [9], surge el Ajuste Fino Eficiente en Parámetros (PEFT). Esta estrategia congela la mayoría de los pesos originales y optimiza solo una fracción minúscula. Su variante más destacada, LoRA [67], inyecta pequeñas matrices de descomposición entrenables en las capas de la red: en lugar de actualizar una matriz de pesos completa (e.g., $4096 \times 4096 = 16\text{M}$ parámetros), la aproxima como el producto de dos matrices de rango reducido r , resultando en solo $2 \times (4096 \times r)$ parámetros entrenables. Las actualizaciones se escalan mediante un factor α , que en la práctica suele fijarse al doble del rango para controlar la magnitud de la adaptación. A mayor rango, mayor capacidad expresiva pero más parámetros;

3.3. Evolución de las Arquitecturas para NER

con valores típicos de $r \in [8, 128]$ se reducen los parámetros en varios órdenes de magnitud sin añadir latencia en inferencia.

La cuantización reduce la precisión numérica de los pesos de un modelo, pasando por ejemplo de 16 bits a 4 bits por parámetro, lo que disminuye drásticamente el consumo de memoria a costa de una pequeña pérdida de precisión. El resultado práctico es considerable: un modelo de 8B parámetros que en 16 bits ocupa aproximadamente 16 GB de VRAM se reduce a 4-5 GB, haciendo viable su entrenamiento en hardware comercial como el disponible en este trabajo.

Llevando esta eficiencia más allá, Dettmers et al. [68] introducen QLoRA, que separa el almacenamiento del cómputo aplicando LoRA mediante tres innovaciones principales. La primera es el formato NF4 (*NormalFloat 4-bit*), que mantiene los pesos congelados en 4 bits (normalizándolos en torno al cero, región donde se concentra la mayor parte de los parámetros) y los descuantiza dinámicamente a 16 bits durante el paso hacia adelante para ejecutar las operaciones matriciales. La segunda es la cuantización doble, que comprime las constantes de escala necesarias para revertir la compresión ahorrando aproximadamente 0,37 bits por parámetro adicionales. Por último, la paginación dinámica transfiere temporalmente a la RAM del sistema los picos de memoria del optimizador. Como ilustra la Figura 3.2, esta combinación permite entrenar modelos masivos en hardware comercial sin sacrificar capacidad predictiva.




Figura 3.2: Comparativa arquitectónica y de consumo de memoria entre el ajuste fino completo, LoRA y la aproximación QLoRA. Fuente: [68]

El estudio de Obeidat et al. [11] ilustra estas ventajas: aplicaron QLoRA con rango 128 a Mistral-7B y Llama-3.1-8B superando a los mejores encoders en NER biomédico, mientras que el SFT completo empeoró el rendimiento, sugiriendo sobreajuste con corpus reducidos y posicionando QLoRA como técnica de regularización. La ventaja fue especialmente clara en entidades de tres o más tokens. Sin embargo, documentaron una limitación relevante: la inferencia con LLMs requiere entre 2 y 11 segundos por documento frente a los 0,05 segundos de los encoders, lo que apunta a que estos siguen siendo más competitivos en escenarios de tiempo real.

3.3.4.3. Arquitecturas Decoder de Referencia

El panorama de modelos propietarios actuales presenta una intensa competencia entre diversas opciones como Gemini o Claude, aunque tradicionalmente ha estado dominado por la familia GPT. Aunque la aplicación de un Afinamiento Supervisado (SFT) a través de su API genera costes económicos elevados, reduce la flexibilidad operativa y compromete la privacidad al externalizar datos clínicos sensibles [11], en este trabajo se incluye el afinamiento de GPT-4.1 mini (lanzado en abril de 2025). La incorporación de este modelo comercial sirve como una referencia para contrastar su rendimiento frente a las soluciones abiertas. Históricamente, las limitaciones de costes impulsaban el uso de enfoques *few-shot*, los cuales suelen ofrecer un rendimiento inferior debido a la inestabilidad en el formato de las respuestas [8, 4]. Esto, sumado a la necesidad de garantizar la soberanía de los datos dentro de las instituciones hospitalarias, justifica la transición hacia alternativas abiertas de tamaño contenido (7B-8B).

La familia Mistral aporta tres de los modelos seleccionados para la evaluación. En primer lugar, Mistral-7B-Instruct-v0.3 [69]⁵, publicado en mayo de 2024, actúa como una referencia estándar ampliamente adoptada en la comunidad gracias a sus sólidos resultados generales. Por otra parte, Ministral-3-8B-Instruct [70]⁶, disponible desde octubre de 2024, representa una variante compacta que destaca por su alta adherencia a las directrices del sistema y un bajo consumo de memoria, lo que la hace ideal para entornos con restricciones de hardware. Finalmente, se incluye BioMistral-7B-DARE [71]⁷, presentado en febrero de 2024, el cual introduce un pre-entrenamiento continuo sobre literatura médica de PubMed Central y utiliza la técnica de fusión *DARE* para integrar el conocimiento especializado sin degradar las capacidades de instrucción originales. Existe un interés explícito en evaluar este modelo junto a Mistral-7B-Instruct-v0.3, ya que al compartir la misma arquitectura base se puede medir con precisión el impacto neto de la especialización de dominio.

La familia Llama 3 [72], desarrollada por Meta, cuenta con la representación de Llama-3.1-8B-Instruct⁸. Lanzado en julio de 2024, este modelo constituye uno de los desarrollos de código abierto más extendidos y, tras haber mostrado resultados que superan a los codificadores tradicionales en tareas biomédicas en inglés [11], se incorpora en este estudio con el propósito de evaluar si dicho rendimiento excepcional es extrapolable al contexto clínico en lengua castellana.

Salamandra-7B-Instruct [73]⁹, modelo entrenado por el Barcelona Supercomputing Center y lanzado en mayo de 2025, ha sido seleccionado debido a su enfoque nativo en el español y las lenguas cooficiales de España. Al contar con un corpus de pre-entrenamiento donde el español representa el 16,12 % del total, su inclusión resulta clave para aislar el efecto directo que ejerce el idioma de procedencia del modelo sobre la resolución de la tarea final.

Por último, se añade Qwen3-8B [74]¹⁰, publicado por Alibaba en abril de 2025. Este modelo destaca por introducir mejoras sustanciales en sus capacidades de razona-

⁵<https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3>

⁶<https://huggingface.co/mistralai/Ministral-3-8B-Instruct-2512>

⁷<https://huggingface.co/BioMistral/BioMistral-7B-DARE>

⁸<https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>

⁹<https://huggingface.co/BSC-LT/salamandra-7b-instruct>

¹⁰<https://huggingface.co/Qwen/Qwen3-8B>

3.3. Evolución de las Arquitecturas para NER

miento lógico y por exhibir una alineación rigurosa en el seguimiento de instrucciones complejas, un factor relevante para la consistencia estructural requerida en el reconocimiento de entidades nombradas.

A modo de síntesis, la Tabla 3.4 resume el rendimiento de los modelos generativos documentado en la literatura científica reciente. Es necesario recalcar que los resultados reportados se limitan a estos corpus específicos en inglés debido a que no se han probado ni evaluado previamente en el idioma español. Los datos recopilados sugieren que la aplicación de técnicas de adaptación eficiente como QLoRA permite que arquitecturas como Llama y Mistral superen a los codificadores tradicionales en estos benchmarks, eludiendo los desproporcionados costes computacionales vinculados al afinamiento supervisado completo [11].

Modelo	Paradigma	Cita	BC5CDR	BioRED	JNLPBA	ChemProt	Reddit	NCBI	BC2GM
Codificadores de Dominio (Encoders)									
BiomedBERT (large)	Full SFT	[11]	88,42	89,08	73,09	50,74	23,78	-	-
DeBERTa (v3-large)	Full SFT	[11]	88,86	88,88	73,59	45,57	21,36	-	-
PubMedBERT	Full SFT	[9]	93,30	-	-	-	-	87,30	83,00
Modelos Generativos (ICL / Few-shot)									
GPT-4 (5-shot)	In-Context	[9]	81,10	-	-	-	-	58,60	49,40
GPT-3.5 (5-shot)	In-Context	[9]	35,50	-	-	-	-	31,80	39,50
Modelos Generativos Afinados									
Mistral-7B (Instruct)	QLoRA	[11]	90,73	88,46	75,67	52,43	31,65	-	-
Llama-3.1-8B (Instruct)	QLoRA	[11]	89,48	88,58	74,85	53,03	29,68	-	-

Cuadro 3.4: Comparativa unificada de rendimiento (F1 estricto) extraída de Obeidat et al. (2025) [11] y Keloth et al. (2024) [9]. Los valores de BC5CDR no son directamente comparables: Obeidat evalúa químicos y enfermedades conjuntamente, mientras que Keloth extrae únicamente químicos. Fuente: Elaboración propia.

Entre el ecosistema de modelos abiertos generalistas excluidos de esta selección cabe mencionar opciones como Phi de Microsoft, Gemma de Google DeepMind o Granite de IBM, además de soluciones médicas como MedAlpaca. Considerando que los modelos discriminativos basados en arquitecturas de codificación continúan liderando el estado del arte en el ámbito hispanohablante [28], resulta pertinente analizar hasta qué punto los recientes avances en modelos generativos son capaces de igualar o superar dicho rendimiento en español. El capítulo siguiente describe la metodología experimental diseñada para evaluar comparativamente ambos paradigmas.

Capítulo 4

Metodología y Diseño Experimental

Este capítulo describe el marco metodológico aplicado en el proyecto. Se presenta el entorno de trabajo, el tratamiento de los datos, el diseño del entrenamiento para ambos paradigmas y el esquema de evaluación común utilizado para comparar resultados. El código fuente íntegro desarrollado para estos procesos se encuentra disponible de forma pública en el siguiente repositorio de GitHub¹.

En ambos paradigmas, cada corpus se trata de forma independiente: DisTEMIST se formula como una tarea de reconocimiento de ENFERMEDAD y ProcTEMIST como una tarea de PROCEDIMIENTO, con entrenamiento y evaluación separados en cada caso.

4.1. Entorno de Implementación

El desarrollo se llevó a cabo utilizando el entorno en la nube de Kaggle. Este entorno está equipado con dos aceleradores gráficos NVIDIA T4 Tensor Core que proporcionan un total de 30 GB de memoria VRAM (15 GB cada una), complementadas con 30 GB de memoria RAM.

El ecosistema de software se fundamenta en Python y se organiza en tres bloques:

- **Librerías comunes:** PyTorch, Transformers, Datasets, spaCy, pandas y NumPy.
- **Librerías para codificadores:** Evaluate y Sequeval.
- **Librerías para decodificadores:** Unsloth, PEFT, TRL, Bitsandbytes y Accelerate.

4.2. Preprocesamiento de Datos

Los corpus clínicos descritos en la Sección 3.2.2 (DisTEMIST y ProcTEMIST) se someten a un proceso de adecuación previo al entrenamiento para garantizar consistencia entre texto, anotaciones y evaluación. En su formato original, tanto *train* como *test* combinan documentos clínicos en texto plano (`.txt`) y anotaciones en archivos tabulares (`.tsv`), siguiendo una lógica similar a la mostrada en la Figura 3.1.

¹https://github.com/Honricris/Trabajo_Fin_Master

Cada archivo de anotaciones incluye las columnas: `filename` (documento de origen), `mark` (ID de anotación), `label` (tipo de entidad), `start` (posición inicial en caracteres), `end` (posición final) y `span` (texto de la mención).

Segmentación en oraciones. La segmentación del texto en fragmentos responde a una limitación práctica de los modelos codificadores: aunque técnicamente pueden procesar secuencias de cualquier longitud, su rendimiento se degrada progresivamente a partir de los 512 tokens, umbral para el que fueron pre-entrenados. Al diseñar la estrategia para los decodificadores se planteó la posibilidad de ingerir documentos completos; no obstante, mediante experimentación se comprobó que aplicar esta misma segmentación mejora de forma notable su rendimiento. En consecuencia, se adoptó el procesamiento por oraciones individuales como configuración definitiva para ambos paradigmas.

Los límites de oración se detectan con el modelo neuronal `es_core_news_md` de spaCy [75], que identifica fronteras sintácticas mediante análisis de dependencias, capturando relaciones estructurales que una regla léxica basada en puntuación no puede resolver. Por ejemplo, abreviaturas como *v.o.* o *i.v.* generan falsos límites que un segmentador simple fragmentaría incorrectamente. Como se puede apreciar en el siguiente fragmento real del corpus:

alprazolam (1-2 mg v.o. /8 h). Acude al médico de Atención Primaria. . .

spaCy identifica correctamente el único límite de oración en *h).*, evitando que el punto de *v.o.* produzca un fragmento inválido. El análisis cuantitativo que justifica esta decisión se detalla en la Figura 5.2.

4.2.1. Preparación para Codificadores

La preparación para codificadores transforma las anotaciones por *offsets* en etiquetas BIO. Este proceso se implementa en `Scripts/temist_to_bio.py`.

Tokenización. El texto se segmenta mediante una expresión regular `(\w+|[\^\w\s])` que produce dos tipos de unidades a nivel de palabra: secuencias de caracteres alfanuméricos y signos de puntuación aislados. Esta segmentación, previa a la tokenización en subtokens propia de cada modelo, sirve únicamente para asignar las etiquetas BIO a partir de los *offsets* del corpus. Los signos de puntuación adyacentes a un span anotado reciben la etiqueta `O` aunque queden dentro de sus límites, normalizando los bordes de las entidades y reduciendo discrepancias de *offset* frente al gold standard en la evaluación estricta.

Ejemplo: en *Dolor abdominal, severo.* se obtiene *Dolor | abdominal | , | | severo | ..* Si la entidad es *Dolor abdominal*, estos tokens se marcan como entidad (`B/I`) y la coma queda aislada como `O`.

Alineación de etiquetas. Para cada token se compara su rango de caracteres con las anotaciones del corpus. Si el token comienza justo donde empieza una entidad, se marca `B` (0); si cae dentro de la entidad pero no en su inicio, se marca `I` (1); si no pertenece a ninguna entidad, se marca `O` (2).

Salida JSONL. El resultado se guarda en formato JSONL, donde cada línea representa un documento con tres campos: `text` (texto original), `tokens` (lista de tokens) y `ner_tags` (lista de etiquetas BIO). Ejemplo:

```
{"text": "Mujer de 74 anos...", "tokens": ["Mujer", "de", "74", "anos", "..."],  
  "ner_tags": [2, 2, 2, 2, ..., 0, 1, 2, ...]}
```

4.2.2. Preparación para Decodificadores

A diferencia de los codificadores, los modelos decodificadores no requieren transformar las anotaciones en esquemas BIO ni alinear etiquetas con subtokens. Cada documento se procesa directamente desde el `.txt` original, aplicando la segmentación en oraciones con spaCy durante el entrenamiento e inferencia para encapsular cada fragmento en un *prompt* estructurado. La localización de las menciones predichas sobre el texto original se realiza mediante búsqueda por expresión regular, conservando los *offsets* respecto al documento completo. Este proceso se detalla en la Sección 4.4.

4.3. Implementación de Modelos Codificadores

En esta sección se implementan los modelos encoder descritos previamente en la Subsección 3.3.3. Las arquitecturas se entrenaron de manera individual sobre DisTEMIST y ProcTEMIST, manteniendo una misma configuración experimental y adaptando solo el espacio de etiquetas a cada tarea.

4.3.1. Preparación de secuencias

El corpus se carga a partir de los ficheros JSONL generados en el preprocesamiento, donde cada token ya porta su etiqueta BIO asignada a nivel de palabra. Cada documento se divide entonces en oraciones mediante spaCy, agrupando los tokens y sus etiquetas por segmento. Sobre cada oración, el `AutoTokenizer` nativo de la arquitectura aplica una segunda tokenización a nivel de subtoken (BPE, WordPiece o SentencePiece según el modelo), propagando la etiqueta de cada palabra a todos sus subtokens resultantes; los subtokens continuadores de un token B se marcan como I para preservar la coherencia del esquema BIO.

4.3.2. Entrenamiento y validación

El entrenamiento se implementa con validación cruzada y repetición por semillas, con particionados reproducibles mediante `np.random.default_rng`. Para adaptar el coste computacional al tamaño del modelo, se emplearon dos regímenes:

- **Modelos de aproximadamente 125M de parámetros:** 5 folds y 2 semillas (123, 4242), para un ensamble de 10 modelos.
- **Modelos de aproximadamente 560M de parámetros:** 3 folds y 1 semilla, para un ensamble de 3 modelos.

La combinación de *folds* y semillas maximiza la diversidad del ensamble: los *folds* garantizan que cada modelo se entrene sobre particiones distintas, mientras que las semillas diversifican la inicialización y el orden de los ejemplos, reduciendo la varianza de la predicción final respecto a cualquier modelo individual. El ensamble se construye sobre réplicas de un mismo modelo, y no combinando arquitecturas distintas, para aislar el rendimiento individual de cada una. Esta estrategia tiende a producir mejores resultados que entrenar un único modelo sobre el 100% de los

datos, gracias a la complementariedad entre modelos entrenados en subconjuntos distintos.

En ambos casos se mantiene la misma metodología de entrenamiento y evaluación, cambiando únicamente el presupuesto de cómputo. Por ello, la comparación se interpreta en clave de rendimiento bajo restricción de recursos y no como igualdad estricta debido al coste computacional. Tras tokenizar, cada partición se transforma al formato que necesita el modelo y `Trainer` optimiza la *loss* interna de token classification (`CrossEntropyLoss`) sobre los tokens activos, ignorando los valores `-100`. Para garantizar reproducibilidad, se fijan las semillas de `random`, `NumPy`, `PyTorch` y `CUDA`; además, la evaluación y el guardado de *checkpoints* se realizan por época, reteniendo el mejor modelo según la métrica interna.

La selección de hiperparámetros se basa en [58], donde se realiza una búsqueda mediante *grid search* para identificar configuraciones óptimas y se reporta el mejor resultado en competición. En este trabajo, tras realizar distintos experimentos comparativos, se observó la superioridad de esa configuración, que se adoptó como referencia experimental.

La configuración de entrenamiento fija los siguientes hiperparámetros:

- **Épocas:** 20.
- **Batch Size:** 16.
- **Learning rate:** $8.516e-5$.
- **Weight decay:** 0.1844.
- **Dropout:** 0.1 (en capas ocultas, atención y clasificador).
- **Warmup ratio:** 0.1.
- **Precisión mixta:** `bf16=True`.
- **Parada temprana:** paciencia de 5 épocas y umbral $1e-4$.
- **Optimización de memoria:** *gradient checkpointing* activado.

Esta elección busca equilibrar reproducibilidad y desempeño, priorizando una configuración respaldada por evidencia previa y validada empíricamente en tareas afines. El optimizador utilizado en el entrenamiento es `AdamW`. Esta variante de Adam separa explícitamente el término de *weight decay* de la actualización del gradiente, lo que suele mejorar la generalización y reducir el riesgo de sobreajuste, especialmente en tareas con datos limitados.

4.3.2.1. Discriminative fine-tuning

Sobre el optimizador anteriormente mencionado (`AdamW`), se aplica *discriminative fine-tuning* agrupando los parámetros por profundidad en 3 grupos, además de *embeddings* y *head*. La capa de salida y las capas superiores conservan la tasa de aprendizaje base, mientras que las capas inferiores y *embeddings* reciben tasas progresivamente menores mediante un factor de decaimiento de 0.95. Este valor reduce la perturbación sobre las capas inferiores del modelo, cuyas representaciones de dominio clínico conviene preservar en mayor medida.

Como referencia, la distribución de grupos de aprendizaje puede representarse como sigue:

```
Grupos LR discriminative FT:  
- embeddings: lr=0.00006936, params=38998272, tensors=5  
- encoder_0: lr=0.00007301, params=28351488, tensors=64  
- encoder_1: lr=0.00007686, params=28351488, tensors=64  
- encoder_2: lr=0.00008090, params=28351488, tensors=64  
- head: lr=0.00008516, params=2307, tensors=2
```

Esta pauta ilustra la reducción progresiva del *learning rate* hacia capas más profundas.

4.3.2.2. Evaluación con Segeval

Durante el entrenamiento, la validación interna se realiza con `segeval` a partir de predicciones BIO a nivel de token. Esta métrica no acumula aciertos aislados por token, sino que evalúa entidades de forma conjunta: para contabilizar un acierto exige la coincidencia exacta de toda la secuencia, el token de inicio B, sus continuadores I y los límites precisos de la mención. Tras omitir los valores -100 correspondientes a tokens especiales, se reconstruyen las secuencias verdaderas y predichas para calcular precisión, *recall* y F1-score.

La elección de `segeval` como métrica interna responde a dos motivos. En primer lugar, opera directamente sobre las secuencias BIO, alineándose con la señal de aprendizaje del modelo. En segundo lugar, es computacionalmente más eficiente que la evaluación estricta, que exige destokenizar el texto y verificar *offsets* exactos sobre el texto crudo. Sin embargo, esta eficiencia tiene un coste: `segeval` evalúa entidades a nivel de secuencia de subtokens sin verificar su posición exacta en el texto original, por lo que una entidad puede considerarse correcta aunque sus límites de carácter difieran ligeramente del gold standard. En la evaluación estricta final, ese mismo desajuste genera un *FP* y un *FN*, produciendo una caída de F1 que puede ser sistemática en texto clínico, donde los tokenizadores por subtokens separan con frecuencia la puntuación adyacente a los términos médicos como un token independiente, desplazando el *offset* final de la entidad. Este fenómeno se ilustra con un ejemplo real en la Figura 4.1 y explica parte de la divergencia entre las métricas internas reportadas en la literatura y los resultados estrictos de este trabajo.

Por último, la selección del mejor modelo en cada *fold* se basa en `eval_f1` en lugar de `eval_loss`. En NER, el fuerte desbalance de clases por la predominancia de la etiqueta O permite reducir la pérdida simplemente clasificando bien los tokens irrelevantes, sin mejorar la detección de menciones médicas. El F1 a nivel de entidad penaliza falsos positivos y falsos negativos, representando de forma más fiel la utilidad real del sistema.

4.3.3. Ensamble e inferencia

La inferencia final sobre *test* se realiza mediante un ensamble de los modelos entrenados en cada configuración. Cada modelo procesa el texto documento a documento, pero la predicción se aplica por oraciones para evitar problemas de truncación y conservar la correspondencia de los *offsets*. Posteriormente, las entidades detectadas se reubican sobre el texto completo sumando el desplazamiento inicial de cada oración.

4.4. Implementación de Modelos Decodificadores



Figura 4.1: Comparativa entre *segeval* y la evaluación estricta por *offsets* sobre un ejemplo real. Fuente: Elaboración propia.

El ensamble utiliza voto por mayoría con un umbral del 50 % de los modelos activos; en términos prácticos, una mención se conserva cuando alcanza al menos la mitad de votos (por ejemplo, 5 de 10 o 2 de 3 tras redondeo al entero superior). El voto no se aplica sobre tokens individuales, sino sobre menciones ya agregadas por modelo, identificadas por (*filename*, *off0*, *off1*). En este esquema monoetiqueta por corpus, se filtra la etiqueta objetivo de la tarea y se generan las predicciones finales en formato TSV con las columnas *filename*, *mark*, *label*, *off0*, *off1* y *span*.

Además del TSV final, se registra un resumen de inferencia (umbral de voto y tiempos) para facilitar la trazabilidad experimental.

Este TSV constituye la salida que se compara posteriormente con el *gold standard* en la Sección 4.5.

4.4. Implementación de Modelos Decodificadores

A diferencia de los codificadores, los modelos decodificadores abordan el NER como una tarea de generación de texto: dado un fragmento clínico, el modelo genera directamente el listado de menciones presentes en él. Se evalúan tres configuraciones: *zero-shot* y *few-shot* sin actualización de pesos, y *fine-tuning* con QLoRA para adaptar el modelo a la tarea.

4.4.1. Carga del modelo

La integración de la librería Unsloth resulta un añadido en este trabajo. Esta herramienta destaca por ofrecer acceso directo a modelos precuantizados a 4 bits, lo que reduce drásticamente el tiempo de preparación y la huella de memoria inicial. Además, sustituye las operaciones nativas por kernels en Triton optimizados a bajo

nivel, logrando duplicar la velocidad del entrenamiento y minimizando el consumo de memoria residual sin comprometer significativamente la capacidad predictiva del modelo final [76].

En la práctica, la configuración y carga del modelo base se gestionan a través de la interfaz `FastLanguageModel`. Los pesos preentrenados se alojan congelados en la VRAM bajo el formato de 4 bits NF4. Para mantener la precisión, estos tensores se descuantizan dinámicamente a `Float16` durante los pases hacia adelante y hacia atrás, garantizando así la exactitud matemática de las operaciones algebraicas y del flujo de gradientes.

Finalmente, la ventana de contexto se establece en 1024 tokens. Mediante la técnica de relleno dinámico, el consumo de memoria de cada lote iterativo se ajusta a la secuencia más larga presente, por lo que este límite superior no penaliza el rendimiento temporal. Esta configuración actúa como una red de seguridad contra desbordamientos de memoria frente a posibles ejemplos anómalos, ya que la longitud máxima real registrada en el corpus es de 582 tokens.

4.4.2. Adaptadores LoRA

En lugar de actualizar todos los parámetros del modelo, se inyectan adaptadores LoRA sobre un subconjunto de capas. Tras realizar distintos experimentos comparativos, se determinó que la configuración óptima emplea $r = 64$ y $\alpha = 128$; siguiendo la práctica habitual en la literatura, el factor de escala se fija al doble del rango. Respecto a las capas objetivo, se utiliza `target_modules = "all-linear"`, lo que aplica los adaptadores sobre todas las capas lineales del modelo, es decir, las proyecciones de consulta, clave, valor y salida de la atención, así como las capas de las redes MLP. A modo ilustrativo, en el caso de Ministral-3, esta configuración resulta en 215.613.440 parámetros entrenables, lo que representa aproximadamente el 2,36% del total de 9.133.639.680 parámetros del modelo, manteniendo el resto congelado.

4.4.3. Construcción del dataset y diseño del prompt

Cada documento de entrenamiento se segmenta en oraciones mediante `spaCy`, donde cada oración constituye un chunk independiente. Cada chunk se encapsula en un *prompt* estructurado como una conversación. En su configuración base, consta de tres turnos: un turno de sistema con las instrucciones de extracción, un turno de usuario con el texto a analizar y un turno de asistente con las menciones del chunk, una por línea, en el orden en que aparecen. En los cuadernos de evaluación *five-shot*, esta estructura se amplía manteniendo el mensaje de sistema al inicio y encadenando pares alternos de turnos de usuario y asistente con los ejemplos de demostración previos a la consulta final.

El diseño del *prompt* y la selección de los ejemplos se construyeron iterativamente sobre ambos corpus empleando Ministral (el decodificador de mayor rendimiento), refinándolos empíricamente hasta maximizar las métricas en las evaluaciones previas *zero-shot* y *five-shot*. Los textos definitivos para ambos conjuntos de datos se recogen en el Apéndice A.

Las menciones se asignan a cada chunk filtrando por *offsets* de carácter, garantizando que cada mención queda asociada exclusivamente al fragmento donde aparece. Si el chunk no contiene menciones, el turno de asistente queda vacío, constituyendo un

4.4. Implementación de Modelos Decodificadores

ejemplo negativo. Es importante destacar que el formato del *prompt* para el entrenamiento supervisado (SFT) es estrictamente *zero-shot*. Puesto que la actualización de pesos ya internaliza el formato y la instrucción de la tarea, inyectar ejemplos en contexto (*few-shot*) durante el SFT resulta redundante y consume tokens de forma ineficiente.

El parámetro `MAX_CHUNK_CHARS` permitía originalmente agrupar varias oraciones en un único fragmento más largo. Sin embargo, tal y como se introdujo en la Sección 4.2, el estudio experimental indicó que aislar cada oración delimitada por `spaCy` (con una longitud media de 262 caracteres) produce los mejores resultados. El análisis empírico de este efecto se recoge en la Sección 5.2.1. De forma análoga, se comprobó que reducir la proporción de ejemplos negativos mediante `MAX_NEGATIVE_RATIO` degradaba el rendimiento, por lo que se incorporan en su totalidad.

A modo ilustrativo, las estadísticas del dataset para Ministral-3 son las siguientes; los valores varían según el tokenizador de cada modelo:

```
Dataset: 11713 chunks | Positivos: 5185 | Negativos: 6528
Tokens -- min:219  max:582  media:262  p95:315  Truncados(>1024): 0
```

4.4.4. Entrenamiento

La selección de hiperparámetros parte de dos referencias: la guía de Unsloth² y el trabajo de Obeidat et al. [11], ajustando cada parámetro de forma individual sobre la arquitectura Ministral. Como ejemplo, Obeidat et al. emplean 20 épocas, mientras que la guía recomienda entre 1 y 3; valor que se validó experimentalmente mediante una partición 80/20, observando que a partir de la segunda época los modelos tienden a sobreajustar en esta tarea.

El entrenamiento final se realiza con `SFTTrainer` sobre el 100% de los datos de entrenamiento, lo que bajo la configuración de 2 épocas aportó aproximadamente 0,5 puntos adicionales de F1 respecto a la partición 80/20.

El *data collator* es el componente encargado de agrupar los ejemplos individuales en lotes y aplicar las transformaciones necesarias antes de pasarlos al modelo. El empleado en este trabajo (`DataCollatorForCompletionOnlyLM`) enmascara los tokens del prompt asignándoles la etiqueta `-100`, de modo que la *loss* se calcula únicamente sobre la respuesta del asistente. A diferencia de los codificadores, donde se compara la distribución predicha sobre etiquetas BIO con la etiqueta correcta, aquí se compara la distribución del modelo sobre el vocabulario completo con la distribución ideal que asigna probabilidad 1 al siguiente token correcto de la respuesta y 0 al resto.

Los hiperparámetros principales son los siguientes:

- **Épocas:** 2.
- **Batch size efectivo:** 32 (batch de 1 con acumulación de 32 pasos).
- **Learning rate:** $3e-5$ con *scheduler* lineal y *warmup ratio* de 0.05.
- **Weight decay:** 0.01.
- **Norma máxima del gradiente:** 0.3.

²<https://unsloth.ai/docs/get-started/fine-tuning-llms-guide/lora-hyperparameters-guide>

- **Precisión mixta:** `fp16`.
- **Optimizador:** `paged_adamw_8bit`, una variante de AdamW que mantiene los estados del optimizador en precisión de 8 bits, reduciendo el consumo de memoria hasta un 75 % respecto a su equivalente en 32 bits, con paginación dinámica tal como se describió en la Sección 3.3.4.2.

A diferencia de los codificadores, no se emplea validación cruzada ni ensamble de modelos: el elevado coste computacional, con tiempos de entrenamiento de aproximadamente 10 horas por modelo, hace inviable esta estrategia. Se entrena por tanto un único modelo y se utiliza directamente para la inferencia.

4.4.5. Inferencia y recuperación de *offsets*

Durante la inferencia, cada documento se segmenta en bloques de oraciones (*chunks*) mediante spaCy. Cada bloque se procesa de forma independiente con el modelo en modo evaluación, utilizando decodificación *greedy*. La salida consiste en texto plano donde cada línea representa una mención clínica detectada. Además, se integra un control de memoria dinámico para limpiar la caché de la GPU y evitar de forma segura posibles desbordamientos (OOM) durante la generación continua.

Dado que el modelo generativo solo produce el texto de la entidad, es imprescindible calcular sus posiciones exactas (*offsets*) dentro del documento original. La recuperación se realiza mediante expresiones regulares insensibles a mayúsculas y neutralizadas contra caracteres especiales (`re.escape`). Para resolver el problema de las menciones repetidas en un mismo bloque, se emplea un diccionario de cursores posicionales específico para cada cadena de texto. La búsqueda de un término comienza en la última posición almacenada por su cursor individual y finaliza en el límite del *chunk*. Si hay coincidencia, el cursor se actualiza al final de la misma; si la búsqueda falla, se ejecuta un reintento de rescate (*fallback*) escaneando desde el principio del bloque. Las menciones que no logran localizarse tras este segundo intento se descartan.

Finalmente, las menciones válidas se unifican a nivel de documento y se ordenan de forma ascendente según su coordenada de inicio. Se aplica un filtrado de deduplicación para eliminar registros con idénticos *offsets* de inicio y fin, y el conjunto resultante se exporta al archivo de predicciones (TSV) referenciado en la Sección 4.5.

4.5. Métricas de Evaluación Comunes

La evaluación final de encoders y decoders compara el TSV de predicciones sobre *test* con el gold standard oficial, aplicándose por igual a ambos paradigmas. Además de la calidad de las extracciones, se registra el tiempo total de inferencia para que la comparación entre configuraciones tenga en cuenta también el coste computacional.

4.5.1. Evaluación Estricta por Offsets Exactos

Una extracción se considera correcta únicamente si coincide con la referencia en documento, etiqueta y *offsets* de carácter. Cualquier desviación de un carácter invalida la predicción: la mención predicha cuenta como *FP* y la mención de referencia no

recuperada exactamente cuenta como *FN*. Con ese criterio se obtienen *TP*, *FP* y *FN*, y se calculan precisión, *recall* y F1-score:

$$P = \frac{TP}{TP + FP} \quad R = \frac{TP}{TP + FN} \quad F1 = 2 \cdot \frac{P \cdot R}{P + R} \quad (4.1)$$

Este criterio, más exigente que *seqeval*, constituye la métrica definitiva del sistema y es la que permite comparar resultados con los trabajos del estado del arte que también la adoptan. Dado que penaliza cualquier desajuste de límites, los valores obtenidos deben interpretarse como una estimación conservadora del rendimiento real, tal y como ilustra la Figura 4.1.

4.5.2. Evaluación por Solapamiento (IoU)

Junto a la métrica estricta, se evalúa cada sistema bajo tres umbrales de solapamiento entre el *span* predicho y el de referencia. El grado de solapamiento se cuantifica mediante la intersección sobre la unión (*IoU*) de los intervalos de caracteres:

$$IoU = \frac{\max(0, \min(p_1, g_1) - \max(p_0, g_0))}{\max(p_1, g_1) - \min(p_0, g_0)} \quad (4.2)$$

donde $[p_0, p_1)$ es el intervalo predicho y $[g_0, g_1)$ el de referencia. Un *IoU* de 1 indica coincidencia exacta de límites, es decir, equivale a la evaluación estricta por offsets de la subsección anterior, mientras que valores próximos a 0 indican solapamiento mínimo. Para cada documento, se calcula el *IoU* entre cada *span* predicho y cada *span* de referencia. Los pares se ordenan de mayor a menor *IoU* y se van asignando en ese orden, garantizando que cada *span* predicho y cada *span* de referencia solo puede participar en un emparejamiento. Los *spans* que no alcanzan el umbral o que no encuentran pareja cuentan como *FP* o *FN* respectivamente.

Los umbrales empleados son $IoU \geq 0,0$ (cualquier solapamiento), $IoU \geq 0,5$ y $IoU \geq 0,8$ (casi exacto). El análisis de esta distribución permite clasificar la gravedad de los errores de frontera: un $IoU > 0,8$ sugiere desajustes menores asociados a puntuación o determinantes, mientras que un $IoU \leq 0,5$ denota discrepancias semánticas severas.

4.5.3. Análisis de Fronteras mediante Métrica Delta

Para profundizar en los errores de delimitación, se introduce la métrica delta (Δ) de palabras. Esta medida se calcula como la diferencia total de tokens entre la predicción y el *gold standard*:

$$\Delta = N_{\text{pred}} - N_{\text{gs}} \quad (4.3)$$

La métrica permite identificar de forma cuantitativa el sesgo del modelo. Un $\Delta > 0$ refleja que el modelo añade texto innecesario, un $\Delta < 0$ cuantifica la truncación al omitir información relevante y un $\Delta = 0$ indica un desajuste puramente posicional que mantiene la longitud léxica exacta.

Tiempos de inferencia. Ambos sistemas registran el tiempo de inferencia sobre el conjunto de test, tanto por archivo procesado como en total, lo que permite estimar el coste computacional de cada configuración y compararlo entre paradigmas.

Capítulo 5

Resultados y Discusión

Este capítulo analiza los resultados obtenidos en los experimentos. Primero se evalúa el paradigma discriminativo considerando su estabilidad, eficiencia paramétrica y patrones de error. Posteriormente se examina el paradigma generativo, sus estrategias de adaptación y sus fallos estructurales. El capítulo concluye con una comparación global entre ambos modelos que mide su capacidad predictiva frente al coste computacional.

5.1. Desempeño del Paradigma Discriminativo (Encoders)

En esta sección evaluamos el rendimiento del modelo discriminativo en dos partes. Primero, analizamos las métricas y las estadísticas de los modelos codificadores. Después, examinamos a nivel cualitativo las diferencias encontradas respecto de las anotaciones de referencia.

5.1.1. Análisis Cuantitativo

A continuación se detallan los resultados obtenidos por los modelos codificadores. La Tabla 5.1 expone las métricas finales.

Modelo	DisTEMIST (Enfermedad)			ProcTEMIST (Procedimiento)		
	Precisión	Recall	F1	Precisión	Recall	F1
Líneas Base Generalistas						
XLM-RoBERTa-Large (~560M)	0,802	0,727	0,763	0,804	0,762	0,782
RigoBERTa 2.0 (~560M)	0,806	0,748	0,776	0,811	0,770	0,790
Modelos Clínicos Especializados						
bsc-bio-ehr-es (~125M)	0,809	0,780	0,794	0,816	0,794	0,805
roberta-es-clinical-trials (~125M)	0,816	0,778	0,797	0,803	0,800	0,801
RigoBERTa Clinical (~560M)	0,804	0,730	0,765	0,813	0,774	0,793

Cuadro 5.1: Resultados cuantitativos de los modelos discriminativos (Encoders) bajo evaluación estricta por caracteres en los corpus DisTEMIST y ProcTEMIST. Fuente: Elaboración propia.

Los resultados obtenidos superan los umbrales de los sistemas ganadores en ambas

5.1. Desempeño del Paradigma Discriminativo (Encoders)

competiciones, lo que sugiere que el ensamble basado en validación cruzada es un factor relevante para alcanzar el estado del arte. Como se ilustra en la Figura 5.1, en DisTEMIST el sistema vencedor alcanzó un F1 de 0,777 utilizando bsc-bio-ehr-es con complejas capas de decodificación. En cambio, roberta-es-clinical-trials obtiene un F1 de 0,797 y bsc-bio-ehr-es alcanza 0,794. De igual forma en ProcTEMIST, el primer puesto logró un F1 de 0,798 mediante un ensamble heterogéneo con capas *Masked CRF* y *Multi-head CRF*. Sin embargo, bsc-bio-ehr-es y roberta-es-clinical-trials superan esa marca con un F1 de 0,805 y 0,801 respectivamente, lo que indica que esta estrategia puede superar a arquitecturas más complejas empleando únicamente una capa de clasificación lineal con una función Softmax.

La precisión se mantiene estable en torno a 0,80–0,82 en todos los modelos, lo que sitúa al recall como uno de los factores determinantes del orden de clasificación final: confirmar un span ya detectado es una tarea que el contexto local resuelve con independencia del dominio, pero detectar terminología clínica especializada exige haberla interiorizado durante el preentrenamiento. Por tanto, los modelos especializados de 125M superan consistentemente a los de 560M en recall (0,777–0,800 frente a un máximo de 0,773). El análisis por fold descarta que esta brecha sea un efecto del tamaño del ensamble, ya que también a nivel individual (Tabla 5.2) la brecha es mayor en recall que en precisión, lo que apunta a la capacidad de detección como el principal factor diferenciador.

Dentro de la familia RigoBERTa, la versión generalista supera a la clínica en DisTEMIST (0,776 frente a 0,765) pero la tendencia se invierte en ProcTEMIST (0,793 frente a 0,790). Este patrón es coherente con los resultados publicados [37], donde ambas versiones alcanzan puntuaciones prácticamente idénticas pese a que ClinText-SP incluye los propios textos SPACCC de ambos benchmarks. Esto sugiere que la adaptación continua de dominio no desplaza de forma consistente al modelo base en esta familia de arquitecturas.

Tarea	Modelo	<i>n</i>	Prec. val. (media $\pm$ std)	Recall val. (media $\pm$ std)	F1 val. (media $\pm$ std)	Mín.	Máx.	F1 test	Ganancia
DisTEMIST	bsc-bio-ehr-es	10	0,754 $\pm$ 0,016	0,784 $\pm$ 0,006	0,768 $\pm$ 0,008	0,748	0,779	0,794	+0,015
	roberta-es-clinical-trials	10	0,758 $\pm$ 0,015	0,774 $\pm$ 0,010	0,766 $\pm$ 0,010	0,751	0,784	0,797	+0,012
	RigoBERTa 2.0	3	0,727 $\pm$ 0,005	0,749 $\pm$ 0,011	0,738 $\pm$ 0,004	0,734	0,743	0,776	+0,033
	XLNet-RoBERTa-Large	3	0,725 $\pm$ 0,013	0,731 $\pm$ 0,004	0,727 $\pm$ 0,005	0,723	0,734	0,763	+0,029
	RigoBERTa Clinical	3	0,729 $\pm$ 0,005	0,750 $\pm$ 0,008	0,739 $\pm$ 0,007	0,733	0,748	0,765	+0,017
ProcTEMIST	bsc-bio-ehr-es	10	0,746 $\pm$ 0,020	0,775 $\pm$ 0,015	0,760 $\pm$ 0,016	0,726	0,781	0,805	+0,024
	roberta-es-clinical-trials	10	0,742 $\pm$ 0,016	0,785 $\pm$ 0,016	0,763 $\pm$ 0,014	0,736	0,777	0,801	+0,024
	RigoBERTa 2.0	3	0,732 $\pm$ 0,012	0,747 $\pm$ 0,018	0,739 $\pm$ 0,014	0,722	0,756	0,790	+0,034
	RigoBERTa Clinical	3	0,718 $\pm$ 0,010	0,759 $\pm$ 0,019	0,738 $\pm$ 0,014	0,718	0,748	0,793	+0,045
	XLNet-RoBERTa-Large	3	0,707 $\pm$ 0,005	0,747 $\pm$ 0,014	0,726 $\pm$ 0,009	0,716	0,737	0,782	+0,045

Cuadro 5.2: Estadísticos de precisión, recall y F1 en validación cruzada (media $\pm$ desviación estándar, mínimo y máximo de F1 de los modelos individuales del ensamble) y ganancia del ensamble respecto al mejor modelo individual. Fuente: Elaboración propia.




Figura 5.1: Rendimiento F1 de los ensambles frente al estado del arte y ganancia $\Delta F1$ aportada por el voto por mayoría (der.). Fuente: Elaboración propia.

Los datos de la Tabla 5.2 y su representación gráfica en la Figura 5.1 reflejan una mejora de rendimiento consistente en todos los modelos al pasar de modelos individuales en validación al ensamble de test (+0,012 a +0,045). Esta ganancia es superior en las arquitecturas de 560M frente al menor margen de los modelos de 125M, lo que estrecha la brecha entre ambas familias en la evaluación final. Este comportamiento, especialmente visible en ProcTEMIST, sugiere que el voto por mayoría actúa como un filtro eficaz contra los falsos positivos generados por los modelos individuales, mitigando el ruido inicial mediante el consenso del ensamble y conectando directamente con los patrones cualitativos descritos a continuación.

Como conclusión, sobresale el desempeño de los modelos `bsc-bio-ehr-es` y `roberta-es-clinical-trials`. Estas arquitecturas compactas de 125M de parámetros no solo establecieron el estado del arte en las competiciones oficiales, sino que aquí consolidan su liderazgo al superar a modelos generalistas que cuadruplican su tamaño (~560M). Este resultado coincide con los F1 individuales de validación y es consistente con la idea de que un preentrenamiento de calidad sobre corpus biomédicos e historias clínicas en español aporta un conocimiento del vocabulario médico que ningún incremento de escala sin especialización previa logra compensar por completo.

5.1.2. Análisis Cualitativo de Errores

La evaluación cualitativa se realiza sobre las predicciones del ensamble final de los mejores modelos: `roberta-es-clinical-trials` para DisTEMIST y `bsc-bio-ehr-es` para ProcTEMIST. Los fallos se clasifican en tres grupos de eventos excluyentes sobre el total de errores de cada corpus (771 en DisTEMIST, 1020 en ProcTEMIST).

5.1.2.1. Errores de delimitación de fronteras

Este tipo de fallo constituye, a nivel global, el 35,5 % de los errores totales detectados. Este evento ocurre cuando existe cualquier grado de solapamiento entre la predicción y la entidad real, lo que indica que una proporción considerable de las penalizaciones no corresponden a detecciones completamente equivocadas, sino a predicciones correctas en su núcleo que presentan límites inexactos o fragmentaciones.

5.1. Desempeño del Paradigma Discriminativo (Encoders)

Los archivos que contienen las menciones clínicas presentan una notable diversidad estructural, apareciendo estas tanto de forma aislada como integradas en contextos amplios. Tal como se ilustra en la Tabla 5.3, esta variabilidad complica la delimitación precisa por parte del modelo.

Corpus	Dirección	Gold Standard	Predicción del modelo
DisTEMIST	Truncación	<i>adenopatía axilar bilateral con múltiples focos microscópicos de carcinoma clásico</i>	<i>adenopatía axilar bilateral</i>
		<i>insuficiencia renal crónica</i>	<i>insuficiencia renal</i>
	Extensión	<i>recidiva tumoral en el lecho quirúrgico</i>	<i>recidiva tumoral en el lecho quirúrgico, que infiltraba pilar diafragmático derecho posterior e hígado</i>
		<i>carcinoma pulmonar de células pequeñas</i>	<i>carcinoma pulmonar de células pequeñas sin afectación ganglionar</i>
ProcTEMIST	Truncación	<i>evidencia radiológica</i>	<i>radiológica</i>
		<i>laparotomía hasta la sínfisis del pubis, se revisa de nuevo el abdomen</i>	<i>laparotomía hasta la sínfisis del pubis</i>
	Extensión	<i>anatomopatológico</i>	<i>resultado anatomopatológico</i>
		<i>analgésicos</i>	<i>analgésicos suaves</i>

Cuadro 5.3: Errores de delimitación de fronteras: ejemplos de truncación y extensión por corpus (ensamble discriminativo). Fuente: Elaboración propia.

En DisTEMIST las truncaciones predominan claramente sobre las extensiones (58,0 % frente a 39,7 %), mientras que en ProcTEMIST la distribución se equilibra de forma notable (50,3 % frente a 47,6 %), con errores cruzados residuales en ambos corpus del 2,3 % y 2,1 % respectivamente.

El análisis del delta de palabras cuantifica la magnitud de este recorte: las predicciones pierden, de media, $-1,22$ palabras en DisTEMIST y $-0,85$ en ProcTEMIST. Al examinar los términos descartados, el token más frecuentemente omitido es la preposición «con» (27 veces en ambos benchmarks), seguida de «de» y «y». Esto apunta a que el ensamble tiende a segmentar el texto justo antes de los nexos que unen especificaciones anatómicas al núcleo de la entidad.

El análisis de la Intersección sobre la Unión (IoU) pone de manifiesto la gravedad de estos desajustes. Con un valor medio en torno a 0,5 en ambos corpus, más de la mitad de los errores de frontera (50,8 % en DisTEMIST y 52,9 % en ProcTEMIST) presentan un $\text{IoU} \leq 0,5$. Esto indica que el modelo falla de forma semántica al suprimir o incorporar fragmentos enteros. Por el contrario, los errores leves causados por un simple desajuste de puntuación adyacente ($\text{IoU} > 0,8$) apenas representan el 11,5 % y el 7,5 % respectivamente.

Como se evidencia en la comparativa de la Figura 5.4, esta incapacidad para delimitar

correctamente las fronteras provoca que la detección exacta (*recall*) caiga drásticamente ante entidades largas. Esta excesiva extensión supera la capacidad estructural de la arquitectura discriminativa y causa frecuentemente la fragmentación de menciones complejas en múltiples predicciones aisladas. Por ejemplo, en DisTEMIST el término «*neumonía organizada con bronquiolitis obliterante*» es segmentado en dos extracciones inconexas («*neumonía organizada*» y «*bronquiolitis obliterante*»). Una división similar ocurre en ProcTEMIST con estructuras como «*implante osteointegrado en el mismo tiempo quirúrgico que la extracción del canino incluido*», donde el modelo detecta las acciones por separado e impide la captura unificada del procedimiento clínico.

5.1.2.2. Falsos negativos: omisiones completas

Las omisiones completas representan el 38,3 % del cómputo global de errores, con una incidencia ligeramente superior en DisTEMIST (40,9 %) frente a ProcTEMIST (36,4 %). En estos casos, el modelo no genera ningún solapamiento con la entidad real. Este infraetiquetado se divide en dos grandes bloques según el patrón de texto de la entidad omitida, cuyos ejemplos se muestran en la Tabla 5.4.

1. Limitaciones de vocabulario y términos descriptivos puros

Este bloque concentra el 90,5 % de los falsos negativos en DisTEMIST (37,0 % del total de errores) y el 80,9 % en ProcTEMIST (29,4 % del total). El error ocurre porque la red neuronal carece de la representación interna necesaria para asociar ese vocabulario específico con el dominio clínico. Al no tener interiorizado el término exacto en sus pesos, ignora la entidad por completo independientemente de su longitud.

2. Omisiones por ruido contextual y dependencias largas

Este bloque engloba menciones que incluyen verbos o participios, transformando la entidad en una estructura compleja. Representa el 9,5 % de los falsos negativos en DisTEMIST (3,9 % del total) y el 19,1 % en ProcTEMIST (7,0 % del total). Al procesar estas estructuras, el mecanismo de autoatención debe calcular dependencias a largo plazo. Esta dispersión diluye los pesos de atención sobre la terminología médica clave, lo que puede explicar que la probabilidad predictiva caiga por debajo del umbral de detección.

5.1.2.3. Falsos positivos: detecciones sin solapamiento

Los falsos positivos representan el 26,2 % de los errores globales en ambos corpus. Estas falsas detecciones, sin solapamiento con el estándar de referencia, ocurren porque el modelo depende excesivamente de palabras clave. Al no evaluar la semántica completa, el sistema confunde descripciones anatómicas cotidianas o hallazgos normales con verdaderas entidades médicas (Tabla 5.5).

Esta limitación se aprecia al analizar la longitud de los errores: el 67,0 % en DisTEMIST y el 60,4 % en ProcTEMIST son predicciones de apenas 1 o 2 palabras. Esto indica que el clasificador lineal es propenso a etiquetar términos médicos aislados, sin integrar adecuadamente su verdadero rol dentro del contexto de la oración.

5.1. Desempeño del Paradigma Discriminativo (Encoders)

Corpus	Origen del error	Mención omitida (Gold Standard)
DisTEMIST	Déficit de vocabulario	<i>estreñimiento</i> <i>infiltración del parénquima renal</i>
	Ruido contextual	<i>trombo con nivel quirúrgico IV al presentar situación supradiafragmática llegando al ostium de aurícula derecha</i> <i>dolor abdominal agudo acompañado de náuseas constantes</i>
ProcTEMIST	Déficit de vocabulario	<i>laparotomía subcostal</i> <i>Proteínas totales y fraccionadas</i>
	Ruido contextual	<i>evacuando 7.800 mililitros de contenido serohemático</i> <i>mediante control radiológico, se palpa la cara anterior del hígado</i>

Cuadro 5.4: Ejemplos de omisiones completas (Falsos Negativos) clasificadas por corpus y origen del error. Fuente: Elaboración propia.

Mención (Falso Positivo)	Clase asignada	Naturaleza del error
<i>riñón hidronefrótico</i>	ENFERMEDAD	Detección falsa en contexto descriptivo
<i>riñón de aspecto multiquístico</i>	ENFERMEDAD	Descripción anatómica mal clasificada
<i>flujo Doppler</i>	PROCEDIMIENTO	Modalidad técnica sin acto clínico
<i>valores séricos hormonales</i>	PROCEDIMIENTO	Hallazgo de laboratorio irrelevante
<i>Anatomía Quirúrgica</i>	PROCEDIMIENTO	Referencia bibliográfica mal clasificada

Cuadro 5.5: Ejemplos de falsos positivos: detecciones espurias sin solapamiento. Fuente: Elaboración propia.

5.1.3. Síntesis e implicaciones

Los resultados sugieren que la especialización previa en el dominio médico es un factor determinante para maximizar la detección de entidades. Al combinar este preentrenamiento biomédico con el uso de ensambles, se consigue que modelos compactos de 125M superen holgadamente el rendimiento de arquitecturas generalistas mucho más pesadas.

A pesar de esta alta precisión, la arquitectura discriminativa muestra dificultades evidentes cuando se enfrenta a secuencias largas. La capa de clasificación lineal acoplada a Softmax revela cierta rigidez para mantener el contexto global de la oración, especialmente al procesar nexos o dependencias extensas. Como consecuencia directa de esto, una gran parte de los fallos provienen de recortes estructurales y truncamientos prematuros de las menciones clínicas.

Como respuesta a estas limitaciones de frontera y pérdida de contexto, la siguiente sección explora el paradigma generativo basado en modelos decodificadores. En ella

se analizarán sus estrategias de adaptación al lenguaje clínico, su capacidad para gestionar dependencias a largo alcance y los nuevos patrones de error que introduce el hecho de generar texto en lugar de clasificarlo.

5.2. Desempeño del Paradigma Generativo (Decoders)

Tras haber comprobado las limitaciones estructurales de los modelos discriminativos, este apartado evalúa el comportamiento de las arquitecturas decodificadoras. El análisis abarca tanto su capacidad predictiva global en las distintas fases de adaptación como sus fallos específicos en la delimitación de entidades.

5.2.1. Análisis Cuantitativo

Antes de detallar los resultados globales, se evalúa el impacto del tamaño del contexto introducido en el *prompt*. Como se anticipó en la Sección 4.2, se realizó una ablación sistemática sobre el parámetro `MAX_CHUNK_CHARS` empleando Ministral-3-8B-Instruct en DisTEMIST.

La Figura 5.2 muestra que acortar los fragmentos mejora progresivamente el rendimiento. La ganancia máxima ($\Delta F1 = +3,01$ respecto a la ventana más gruesa) se obtiene al procesar oraciones individuales delimitadas por spaCy, con una longitud media de 262 caracteres. Esta mejora estructural podría explicarse porque, al acortar el texto, se reducen las menciones simultáneas, lo que simplifica la señal de supervisión durante el SFT y minimiza las omisiones o reordenaciones en la generación.



Figura 5.2: Ablación sobre el tamaño máximo de chunk en Ministral-3-8B-Instruct (DisTEMIST). Cada punto corresponde a un experimento SFT completo con QLoRA. Fuente: Elaboración propia.

Bajo esta configuración metodológica basada en oraciones, se exponen a continuación las métricas finales del paradigma generativo en la Tabla 5.6 y la Tabla 5.7. La evolución del rendimiento a lo largo de las distintas fases de adaptación se ilustra en la Figura 5.3.

5.2. Desempeño del Paradigma Generativo (Decoders)

Modelo	Parámetros	F1 0-shot	F1 5-shot	$\Delta F1$	Precisión	Recall	F1 Estricto
Afinamiento Eficiente (QLoRA 4-bit)							
Ministral-3-8B-Instruct	9.13B	0,393	0,434	+0,359	0,809	0,777	0,793
BioMistral-7B-DARE	7.41B	0,097	0,195	+0,575	0,785	0,756	0,770
Meta-Llama-3.1-8B-Instruct	8.20B	0,279	0,362	+0,400	0,784	0,741	0,762
Qwen3-8B	8.37B	0,301	0,294	+0,466	0,774	0,746	0,760
Mistral-7B-Instruct-v0.3	7.42B	0,291	0,218	+0,539	0,766	0,748	0,757
Salamandra-7b-instruct	7.92B	0,209	0,195	+0,523	0,694	0,743	0,718
Afinamiento Supervisado Completo (API)							
GPT-4.1-mini	Cerrado	0,480	0,518	+0,277	0,802	0,788	0,795

Cuadro 5.6: Resultados cuantitativos de los modelos generativos (Decoders) en Dis-TEMIST. Se reporta el rendimiento previo (0-shot y 5-shot) y la ganancia tras el ajuste supervisado ($\Delta F1$). Fuente: Elaboración propia.

Modelo	Parámetros	F1 0-shot	F1 5-shot	$\Delta F1$	Precisión	Recall	F1 Estricto
Afinamiento Eficiente (QLoRA 4-bit)							
Ministral-3-8B-Instruct	9.13B	0,460	0,480	+0,313	0,785	0,802	0,793
Meta-Llama-3.1-8B-Instruct	8.20B	0,214	0,414	+0,368	0,786	0,779	0,782
BioMistral-7B-DARE	7.41B	0,048	0,270	+0,510	0,782	0,778	0,780
Qwen3-8B	8.37B	0,415	0,358	+0,359	0,776	0,770	0,773
Mistral-7B-Instruct-v0.3	7.42B	0,309	0,290	+0,463	0,751	0,793	0,772
Salamandra-7b-instruct	7.92B	0,143	0,225	+0,529	0,744	0,766	0,755
Afinamiento Supervisado Completo (API)							
GPT-4.1-mini	Cerrado	0,578	0,566	+0,238	0,811	0,796	0,803

Cuadro 5.7: Resultados cuantitativos de los modelos generativos (Decoders) en Proc-TEMIST. Se reporta el rendimiento previo (0-shot y 5-shot) y la ganancia tras el ajuste fino ($\Delta F1$). Fuente: Elaboración propia.




Figura 5.3: Gráfico de pendiente del rendimiento F1 de los decodificadores desde zero-shot hasta SFT. Izquierda (DisTEMIST): Umbral ganador F1 = 0,777. Derecha (ProcTEMIST): Umbral ganador F1 = 0,798. Fuente: Elaboración propia.

Dentro del ecosistema abierto, Ministral-3-8B-Instruct lidera el rendimiento con un F1 cercano a 0,79 en ambos corpus. Este resultado supera a los ganadores de las competiciones oficiales y se sitúa a muy poca distancia de los mejores ensambles de codificadores. Aunque el modelo propietario GPT-4.1-mini logra las marcas más altas,

las alternativas libres y compactas alcanzan resultados muy competitivos operando bajo cuantización tanto en su entrenamiento (SFT con QLoRA) como en inferencia, lo que apunta a la viabilidad técnica del despliegue local frente a infraestructuras comerciales.

El análisis del aprendizaje en contexto (ICL) revela que modelos como Ministral, Meta-Llama-3.1 y BioMistral mejoran al incluir ejemplos en el *prompt* (*five-shot*). Mientras tanto, arquitecturas como Qwen3 y Mistral-7B ya los interpretan como ruido de formato, degradando su rendimiento. Esta saturación del contexto se observó también al escalar el experimento a diez ejemplos, cuando el rendimiento decayó en todas las arquitecturas evaluadas. Como se evidenció en la figura anterior, existe una relación directa entre esta adaptabilidad inicial y el éxito tras el ajuste fino, lo que sugiere un salto de rendimiento generalizado al aplicar SFT. Un caso destacado es BioMistral-7B-DARE: aunque su rendimiento cae en zero-shot por la interferencia de su preentrenamiento en inglés, el SFT redirige con éxito su conocimiento médico latente y le permite superar a su modelo base. En el extremo opuesto, Salamandra-7b-instruct (diseñado específicamente para el español) obtiene los peores resultados. Esto sugiere que la especialización en el dominio biomédico podría ser un factor más determinante que la adaptación nativa al idioma.

A nivel de métricas, el paradigma generativo rompe con la regularidad de los codificadores (donde la precisión era estable y el recall definía la clasificación). Los decodificadores muestran una alta fluctuación asimétrica dependiendo de la longitud de la mención. Ante entidades cortas, tienden a la infradetección priorizando la precisión sobre el recall (como ocurre con Meta-Llama-3.1). Frente a estructuras complejas, su dinámica se vuelve expansiva y extraen texto libre en exceso, elevando el recall a costa de la precisión (como Mistral-7B). Dada esta variabilidad, la precisión resulta la métrica más informativa para evaluar la robustez de cada arquitectura frente a la generación inexacta.

En conclusión, los modelos generativos pequeños y ajustados localmente son una opción competitiva y viable para el NER clínico. No obstante, las métricas cuantitativas globales no permiten apreciar completamente sus fortalezas y debilidades en el manejo del lenguaje. A continuación, se presenta un análisis cualitativo detallado de las predicciones para examinar los fallos de delimitación y el comportamiento de estas arquitecturas ante los textos médicos.

5.2.2. Análisis Cualitativo de Errores en Decoders

El análisis detallado sobre un total de 1 834 errores conjuntos revela que el perfil de fallos del paradigma generativo difiere del discriminativo no tanto en su magnitud absoluta como en su distribución. Los errores de delimitación de fronteras concentran el 40,1 % de los fallos globales, los falsos negativos el 30,8 % y los falsos positivos el 29,1 %.

Al contrastar estos valores con los obtenidos previamente (35,5 % de fronteras, 38,3 % de falsos negativos y 26,2 % de falsos positivos), se observa una reducción notable en las omisiones completas de información (7,5 puntos porcentuales menos) que se contrarresta directamente con un incremento de los falsos positivos, los cuales crecen del 26,2 % al 29,1 % (un aumento de 2,9 puntos). Este intercambio ilustra el coste real del paradigma, el cual mitiga las limitaciones de rigidez de los codificadores pero

5.2. Desempeño del Paradigma Generativo (Decoders)

introduce un riesgo superior de sobreconfianza en la generación de texto.

5.2.2.1. Errores de delimitación de fronteras

Los errores de delimitación representan el 40,1 % de los fallos totales (37,2 % en DisTEMIST y 42,1 % en ProcTEMIST). Al igual que ocurría con los codificadores, la métrica de Intersección sobre la Unión (IoU) revela desajustes sustanciales: más del 51 % de estos fallos presentan un $\text{IoU} \leq 0,50$ en ambos corpus. Esto indica que no son discrepancias menores causadas por signos de puntuación adyacentes, sino alteraciones semánticas donde el modelo añade o suprime segmentos enteros de texto.

Sin embargo, el análisis de longitud sí muestra una diferencia importante: los decodificadores presentan un claro sesgo expansivo. De media, añaden +0,19 palabras extra en DisTEMIST y +0,09 en ProcTEMIST, incorporando preposiciones o especificaciones anatómicas vecinas. A diferencia de los codificadores, cuyo comportamiento variaba según el corpus (con predominio de truncaciones en DisTEMIST y mayor equilibrio en ProcTEMIST), los modelos generativos tienden a alargar el texto de forma constante en ambas tareas. Esta regularidad sugiere que la expansión es un fallo intrínseco de la arquitectura y de su inercia al generar tokens, más que un efecto dependiente de la naturaleza gramatical de los términos médicos, tal y como ilustran los ejemplos de la Tabla 5.8.

Corpus	Dirección	Gold Standard	Predicción del modelo
DisTEMIST	Truncación	<i>herida de bala en el muslo derecho</i>	<i>herida de bala en el muslo</i>
	Extensión	<i>cólicos nefríticos de repetición</i>	<i>cólicos nefríticos de repetición con expulsión de litiasis</i>
ProcTEMIST	Truncación	<i>evidencia radiológica</i>	<i>radiológica</i>
	Extensión	<i>exploración física</i>	<i>exploración física se palpaba un testículo izquierdo</i>

Cuadro 5.8: Errores de delimitación de fronteras en el paradigma generativo: ejemplos representativos de truncación y extensión por corpus. Fuente: Elaboración propia.

La comparativa del *recall* (Figura 5.4) muestra una diferencia relevante ligada al sesgo mencionado. Mientras que en entidades cortas (1 a 4 palabras) los codificadores tienen una ligera superioridad o igualdad debido a su precisión localizada, en menciones de gran extensión (8 o más palabras) los decodificadores superan a los encoders por +7,5 puntos en DisTEMIST y +2,8 puntos en ProcTEMIST.

Los codificadores fragmentan las entidades largas porque evalúan las palabras de forma aislada. En contraste, los decodificadores mantienen las secuencias unidas al generar el texto de forma progresiva, lo que les permite captar mejor el contexto global sin romper el concepto médico. Sin embargo, esta fluidez es precisamente lo que parece provocar su sesgo expansivo: el modelo intenta completar la frase de forma natural y no se detiene a tiempo, sobrepasando los límites reales.

Resultados y Discusión




Figura 5.4: Diferencial de *recall* por longitud de span en DisTEMIST (izquierda) y ProcTEMIST (derecha). Discriminativo vs. Generativo. Fuente: Elaboración propia.

5.2.2.2. Falsos negativos: omisiones completas

Las omisiones completas agrupan el 30,8% de los fallos globales del decoder, una proporción inferior al 38,3% observado en los encoders, tal como detalla la Tabla 5.9.

Tipo de Falso Negativo	Encoder	Decoder
Déficit léxico / Vocabulario	32,6 %	28,1 %
Ruido contextual / Sintaxis	5,7 %	2,7 %
Total Falsos Negativos	38,3 %	30,8 %

Cuadro 5.9: Composición global de los falsos negativos por categoría en ambos paradigmas, expresada como porcentaje sobre el total de errores de cada paradigma. Fuente: Elaboración propia.

Los decodificadores superan a los codificadores al procesar textos largos y reducen las omisiones por ruido en el contexto del 5,7% al 2,7%. Además, gracias a su masivo preentrenamiento, estos modelos logran mejorar la cobertura de vocabulario frente a los codificadores. A pesar de esta ventaja, el desconocimiento de palabras muy específicas sigue representando el 28,1% de sus fallos. Si el modelo no asimiló ciertos conceptos clínicos durante su etapa generalista, no podrá identificar términos como *laparotomía subcostal*. Esto sugiere que, aunque la escala de los decodificadores ayuda a mitigar el problema, la falta de grandes modelos entrenados con textos médicos en español sigue siendo una limitación relevante.

5.2.2.3. Falsos positivos: Detecciones sin solapamiento

Las extracciones sin correspondencia en el estándar de referencia representan el 29,1% de los errores totales en los decodificadores. Esto supone un incremento de 2,9 puntos porcentuales respecto a la tasa de falsos positivos de los codificadores (26,2%). Este incremento responde a dos patrones.

El primero es de naturaleza léxica, un problema compartido con el clasificador lineal de los encoders. Más del 60% de estas detecciones erróneas son términos aislados

5.2. Desempeño del Paradigma Generativo (Decoders)

Tipología	Corpus	Mención omitida (Falso Negativo)
Déficit léxico	DisTEMIST	<i>estreñimiento</i> <i>infiltración del parénquima renal</i>
	ProcTEMIST	<i>hallazgos transoperatorios</i> <i>exéresis quirúrgica, separándose la tumoración del conducto deferente</i>
Ruido contextual	DisTEMIST	<i>próstata, que está hiperplásica</i> <i>bala situada a la altura de la sínfisis del pubis</i>
	ProcTEMIST	<i>evacuando 7.800 mililitros de contenido serohemático</i> <i>se palpan dos testículos sanos</i>

Cuadro 5.10: Ejemplos de omisiones completas en el paradigma generativo clasificadas por tipología. Fuente: Elaboración propia.

de una o dos palabras. El modelo reconoce una forma léxica con alta probabilidad clínica e inicia la secuencia de extracción, sin valorar si su rol en la oración justifica su consideración como entidad. Expresiones genéricas como *valores séricos hormonales* o *uropatía obstructiva litiásica* inferidas pero no explícitas ilustran este comportamiento (Tabla 5.11).

El segundo patrón muestra que estos errores no se distribuyen de forma regular por el corpus. Un subconjunto crítico de documentos (apenas el 10 % del total) concentra la tercera parte de todos los falsos positivos en ambas tareas. Al examinar estos textos se observa que corresponden a informes con enumeraciones muy densas de antecedentes médicos o revisiones de laboratorios. Esta saturación de términos parece generar un efecto de retroalimentación en la atención del decoder, provocando un bucle de sobreextracción localizada que degrada la precisión en este tipo de estructuras narrativas específicas.

Mención predicha (Falso Positivo)	Clase asignada	Naturaleza del error
<i>uropatía obstructiva litiásica</i>	ENFERMEDAD	Entidad clínica inferida no explícita
<i>testículo izquierdo hipogénico</i>	ENFERMEDAD	Hallazgo exploratorio mal clasificado
<i>luminograma digestivo</i>	PROCEDIMIENTO	Prueba diagnóstica fuera de rango
<i>valores séricos hormonales</i>	PROCEDIMIENTO	Parámetro de laboratorio analítico

Cuadro 5.11: Ejemplos de falsos positivos en el paradigma generativo. Fuente: Elaboración propia.

5.2.3. Síntesis e implicaciones

El análisis del paradigma generativo revela que los decodificadores mitigan la rigidez sintáctica de los codificadores, mejorando la extracción de entidades largas y reduciendo notablemente los fallos por ruido contextual. Sin embargo, su naturaleza autorregresiva introduce nuevos desafíos: un sesgo expansivo que alarga innecesariamente las fronteras de la predicción y un mayor riesgo de generar falsos positivos

Resultados y Discusión

al inferir términos que no están explícitos en el texto. A esto se suma que, pese a su gran escala, la falta de especialización médica nativa sigue provocando omisiones de vocabulario clave.

En definitiva, mientras que los modelos discriminativos fragmentan las predicciones pero mantienen una alta precisión léxica, los generativos comprenden mejor el contexto global a costa de una delimitación más imprecisa. Dado que ambas arquitecturas presentan un rendimiento final muy similar, la elección de un sistema para un entorno clínico real no puede basarse únicamente en su capacidad predictiva. Por ello, la siguiente sección evalúa ambas familias desde un enfoque operativo, contrastando su rendimiento estricto frente a su coste computacional y tiempo de inferencia.

5.3. Análisis Comparativo Global y Eficiencia Computacional

Para concluir el capítulo de resultados evaluamos ambos paradigmas integrando su rendimiento predictivo y su viabilidad operativa. La Tabla 5.12 reúne las métricas finales y los tiempos de inferencia de todos los sistemas, convergiendo estas cuando se dispone de datos de entrenamiento. La diferencia de F-score entre el mejor modelo codificador y el decodificador de código abierto más destacado es reducida. Resulta especialmente destacable que arquitecturas discriminativas especializadas de apenas 125 millones de parámetros, como `bsc-bio-ehr-es` y `roberta-es-clinical-trials`, superen en rendimiento a sistemas propietarios de mayor escala como GPT-4.1-mini.

Modelo	F1 DisTEMIST	F1 ProcTEMIST	$\bar{t}$ /archivo Dis.	$\bar{t}$ /archivo Proc.
Encoders (ensamble)				
roberta-es-clinical-trials (~125M)	0,797	0,801	0,22 s	0,22 s
bsc-bio-ehr-es (~125M)	0,794	0,805	0,21 s	0,21 s
RigoBERTa 2.0 (~560M)	0,776	0,790	0,38 s	0,39 s
RigoBERTa Clinical (~560M)	0,765	0,793	0,41 s	0,39 s
XLM-RoBERTa-Large (~560M)	0,763	0,782	0,39 s	0,38 s
Decoders (QLoRA 4-bit / API)				
GPT-4.1-mini (API, cerrado)	0,795	0,803	43,13 s	22,37 s
Ministral-3-8B-Instruct (9,13B)	0,793	0,793	22,63 s	36,87 s
BioMistral-7B-DARE (7,41B)	0,770	0,780	13,99 s	16,14 s
Meta-Llama-3.1-8B-Instruct (8,20B)	0,762	0,782	14,02 s	15,28 s
Qwen3-8B (8,37B)	0,760	0,773	18,96 s	19,36 s
Mistral-7B-Instruct-v0.3 (7,42B)	0,757	0,772	17,30 s	17,68 s
Salamandra-7b-instruct (7,92B)	0,718	0,755	12,77 s	14,33 s

Cuadro 5.12: Comparativa global de F1 estricto y tiempo de inferencia por archivo en DisTEMIST y ProcTEMIST. En los encoders, el tiempo corresponde al de un único modelo del ensamble. Fuente: Elaboración propia.

Sin embargo, el escenario diverge radicalmente al analizar la eficiencia computacional. Los codificadores demuestran una superioridad clara al procesar documentos en apenas dos décimas de segundo. Por el contrario, el decodificador más rápido introduce un factor de ralentización superior a 60 veces, mientras que los modelos generativos más precisos multiplican este coste temporal por más de cien. La naturaleza autorregresiva de la generación de texto impone un cuello de botella estructural que contrasta fuertemente con la agilidad de la clasificación lineal simultánea. Esta enorme brecha

5.3. Análisis Comparativo Global y Eficiencia Computacional

temporal tiene consecuencias importantes para su despliegue en entornos clínicos reales donde el volumen de procesamiento es masivo y la latencia puede ser un factor limitante.

A pesar de esta penalización, los modelos generativos aportan un valor diferencial en escenarios de escasez de datos. Mediante estrategias sin entrenamiento previo o con apenas unos pocos ejemplos instruidos en el *prompt*, los decodificadores logran extraer correctamente cerca de la mitad de las entidades clínicas. Esta capacidad de adaptación los convierte en una herramienta prometedora frente a la ausencia total de corpus anotados.

En definitiva, ambos enfoques constituyen estrategias complementarias. Cuando se cuenta con datos de entrenamiento de calidad, los modelos codificadores biomédicos son la solución más adecuada por su precisión léxica y su velocidad. Por su parte, el paradigma generativo se consolida como una alternativa resiliente ante menciones complejas y como un recurso valioso para la extracción clínica en especialidades con recursos limitados. La elección final dependerá de las restricciones de infraestructura y de la disponibilidad real de anotaciones en cada proyecto.

Capítulo 6

Conclusiones y Líneas de Trabajo Futuro

Este trabajo de fin de máster surge para dar respuesta a un vacío de investigación en el Reconocimiento de Entidades Nombradas (NER) clínico en español. Mientras la literatura anglosajona demostraba que los modelos generativos afinados lograban superar a las arquitecturas tradicionales con ventajas de entre el 2 % y el 8 % en la métrica F1-score [11], el panorama hispanohablante seguía dominado por los codificadores y las aproximaciones generativas se restringían a estrategias de aprendizaje en contexto sin ajuste de parámetros [12]. La pregunta central evaluaba si el rendimiento de los grandes modelos de lenguaje (LLMs) de código abierto, optimizados mediante afinamiento supervisado, era capaz de batir el estado del arte establecido por los codificadores. Los hallazgos empíricos sugieren que es posible igualar el rendimiento predictivo, aunque se mantiene el alto coste operativo condicionado a la diferencia de arquitecturas. Mientras que los codificadores procesan la secuencia completa de texto en una única pasada bidireccional y paralela, los decodificadores construyen la respuesta de forma autorregresiva, generando un token tras otro condicionados al contexto anterior, lo que impone un cuello de botella estructural inevitable en su velocidad.

Al entrenar ensambles por validación cruzada sobre modelos como `bsc-bio-ehr-es` o `roberta-es-clinical-trials`, donde cada ensamble agrupa réplicas de una misma arquitectura entrenadas en distintas particiones, se alcanzaron resultados con un F1 de 0,805 en ProcTEMIST y 0,797 en DisTEMIST (Tabla 5.1), superando los umbrales originales de las competiciones fijados en 0,798 y 0,777 respectivamente. A nivel metodológico, los resultados indican que el procesamiento del texto segmentado en oraciones individuales mejora el rendimiento en ambos paradigmas, al reducir el ruido contextual y simplificar la señal de aprendizaje. En cuanto al paradigma generativo, este requiere obligatoriamente una fase de afinamiento supervisado (SFT) para interiorizar la estructura estricta de la tarea. Una vez aplicado este ajuste mediante técnicas eficientes como QLoRA, soluciones abiertas como Ministral-3-8B-Instruct alcanzan un F1 estricto de 0,793 en DisTEMIST y en ProcTEMIST, compitiendo con modelos propietarios como GPT-4.1-mini. Al comparar el *recall* entre ambos paradigmas, emergen sesgos diferenciados: mientras los codificadores dominan en entidades cortas, la generación fluida de los decodificadores les otorga una ventaja para extraer menciones largas y complejas (Figura 5.4). No obstante, esta ventaja introduce un

sesgo expansivo en las fronteras y eleva los falsos positivos por alucinación, además de un cuello de botella que multiplica los tiempos de inferencia entre 60 y 100 veces respecto a los codificadores.

A pesar de esta penalización en latencia, el rendimiento del ecosistema generativo evaluado mediante aprendizaje en contexto (ICL), incluyendo experimentos *zero-shot* y *five-shot*, resulta prometedor. En esta configuración sin ajuste de pesos, modelos avanzados como GPT-4.1-mini alcanzan en *zero-shot* un F1 de 0,480 en DisTEMIST y 0,578 en ProcTEMIST, logrando extraer correctamente cerca de la mitad de las entidades clínicas sin necesidad de entrenamiento previo. Esta capacidad sugiere que arquitecturas de frontera actuales y futuras podrían ofrecer rendimientos competitivos de forma directa sin requerir afinamiento, lo que resulta relevante en situaciones donde no se dispone de corpus anotados, contexto donde los codificadores resultan inviables por su dependencia de los datos de entrenamiento.

En definitiva, la elección entre ambas arquitecturas no radica en la superioridad absoluta de una sobre otra. Si el proyecto cuenta con datos estructurados y requiere eficiencia operativa, los codificadores clínicos constituyen la alternativa más adecuada. Por el contrario, en escenarios de escasez de datos o cuando la prioridad es capturar dependencias narrativas complejas garantizando la privacidad mediante modelos locales, los decodificadores se consolidan como una herramienta capaz de transformar el texto libre en conocimiento médico estructurado.

Los resultados obtenidos abren además varias direcciones de investigación que permitirían consolidar y extender estas conclusiones. En el paradigma discriminativo, la estrategia de ensamble por voto por mayoría simple puede profundizarse mediante mecanismos de agregación más sofisticados, como el promediado de probabilidades a nivel de token, el apilamiento mediante un metamodelo o la ponderación de votos en función del rendimiento individual en validación, con el objetivo de reducir los falsos positivos y mejorar la delimitación de fronteras.

En el paradigma generativo, la evaluación sin ajuste de parámetros se restringió a GPT-4.1-mini como único modelo propietario; una línea natural consiste en ampliar este análisis a modelos más recientes o de mayor escala para determinar si la brecha respecto a los codificadores se estrecha conforme aumenta la capacidad del modelo base y si el ajuste fino con QLoRA sigue siendo necesario en ese escenario.

Finalmente, la metodología desarrollada se ha validado únicamente sobre dos tipos de entidades del dominio TEMIST, por lo que su extensión a corpus de la misma familia, como SympTEMIST o DrugTEMIST, permitiría evaluar si las conclusiones se mantienen ante distintos niveles de complejidad semántica. Adicionalmente, los decodificadores podrían explorarse como generadores de datos sintéticos para reducir el coste de etiquetado manual en especialidades con escasez de anotaciones, combinando así las fortalezas de ambos paradigmas.

Bibliografía

- [1] Jing Li et al. «A survey on deep learning for named entity recognition». En: *IEEE transactions on knowledge and data engineering* 34.1 (2020), págs. 50-70.
- [2] Nandita Goyal y Navdeep Singh. «Named entity recognition and relationship extraction for biomedical text: A comprehensive survey, recent advancements, and future research directions». En: *Neurocomputing* 618 (2025), pág. 129171. ISSN: 0925-2312. DOI: <https://doi.org/10.1016/j.neucom.2024.129171>. URL: <https://www.sciencedirect.com/science/article/pii/S0925231224019428>.
- [3] Wayne Xin Zhao et al. *A Survey of Large Language Models*. 2025. arXiv: 2303.18223 [cs.CL]. URL: <https://arxiv.org/abs/2303.18223>.
- [4] Derong Xu et al. *Large Language Models for Generative Information Extraction: A Survey*. 2024. arXiv: 2312.17617 [cs.CL]. URL: <https://arxiv.org/abs/2312.17617>.
- [5] Imed Keraghel, Stanislas Morbieu y Mohamed Nadif. *Recent Advances in Named Entity Recognition: A Comprehensive Survey and Comparative Study*. 2024. arXiv: 2401.10825 [cs.CL]. URL: <https://arxiv.org/abs/2401.10825>.
- [6] Antonio Miranda-Escalada et al. «Overview of DisTEMIST at BioASQ: Automatic detection and normalization of diseases from clinical texts: results, methods, evaluation and multilingual resources». En: *Working Notes of Conference and Labs of the Evaluation (CLEF) Forum. CEUR Workshop Proceedings*. 2022. URL: <https://ceur-ws.org/Vol-3180/paper-11.pdf>.
- [7] Salvador Lima-López et al. «Overview of MedProcNER Task on Medical Procedure Detection and Entity Linking at BioASQ 2023.» En: *CLEF (Working Notes)*. 2023, págs. 1-18.
- [8] Yan Hu et al. «Improving large language models for clinical named entity recognition via prompt engineering». En: *Journal of the American Medical Informatics Association* 31.9 (ene. de 2024), págs. 1812-1820. ISSN: 1527-974X. DOI: 10.1093/jamia/ocad259. eprint: <https://academic.oup.com/jamia/article-pdf/31/9/1812/58868277/ocad259.pdf>. URL: <https://doi.org/10.1093/jamia/ocad259>.
- [9] Vipina K Keloth et al. «Advancing entity recognition in biomedicine via instruction tuning of large language models». En: *Bioinformatics* 40.4 (mar. de 2024), btae163. ISSN: 1367-4811. DOI: 10.1093/bioinformatics/btae163. eprint: <https://academic.oup.com/bioinformatics/article-pdf/40/4/btae163/57186045/btae163.pdf>. URL: <https://doi.org/10.1093/bioinformatics/btae163>.

-
- [10] Andrei Baroian. *Supervised Fine-Tuning or In-Context Learning? Evaluating LLMs for Clinical NER*. 2025. arXiv: 2510.22285 [cs.CL]. URL: <https://arxiv.org/abs/2510.22285>.
- [11] Motasem S Obeidat, Md Sultan Al Nahian y Ramakanth Kavuluru. *Do LLMs Surpass Encoders for Biomedical NER?* 2025. arXiv: 2504.00664 [cs.CL]. URL: <https://arxiv.org/abs/2504.00664>.
- [12] Álvaro García-Barragán et al. «GPT for medical entity recognition in Spanish». En: *Multimedia Tools and Applications* 84.30 (2025), págs. 36307-36326.
- [13] Parlamento Europeo y Consejo de la Unión Europea. *Reglamento (UE) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos*. Diario Oficial de la Unión Europea (DOUE), L 119/1. Abr. de 2016. URL: <https://www.boe.es/doue/2016/119/L00001-00088.pdf> (visitado 14-12-2025).
- [14] Jefatura del Estado. *Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales*. Boletín Oficial del Estado (BOE), núm. 294, referencia BOE-A-2018-16673. Dic. de 2018. URL: <https://www.boe.es/buscar/pdf/2018/BOE-A-2018-16673-consolidado.pdf> (visitado 14-12-2025).
- [15] Jefatura del Estado. *Ley 14/2007, de 3 de julio, de Investigación biomédica*. Boletín Oficial del Estado (BOE), núm. 159, referencia BOE-A-2007-12945. Jul. de 2007. URL: <https://www.boe.es/buscar/pdf/2007/BOE-A-2007-12945-consolidado.pdf> (visitado 15-12-2025).
- [16] Ander Intxaurrenondo y Martin Krallinger. *SPACCC: The Spanish Clinical Case Corpus*. Data curators: Jose Antonio Lopez Martin, Heidy Rodriguez. Project members: Aitor Gonzalez-Agirre, Marta Villegas. Related person: Montserrat Marimon. Supervisor: Martin Krallinger. Zenodo, 2019. URL: <https://zenodo.org/records/2560316> (visitado 18-12-2025).
- [17] SciELO – Scientific Electronic Library Online. *Guía de Buenas Prácticas para el Fortalecimiento de la Ética en la Publicación Científica*. Versión septiembre 2018. Sep. de 2018. URL: https://scielo.org/documents/50/Guia-de-Buenas-Practicas-para-el-Fortalecimiento-de-la-Etica-en-la-Publicacion_6iNC89c.pdf (visitado 18-12-2025).
- [18] COPE. *COPE – Committee on Publication Ethics*. [Internet]. 2018. URL: <https://www.publicationethics.org> (visitado 18-12-2025).
- [19] ICMJE. *ICMJE – International Committee of Medical Journal Editors*. [Internet]. 2018. URL: <http://www.icmje.org> (visitado 18-12-2025).
- [20] Creative Commons. *Attribution 4.0 International (CC BY 4.0)*. Licencia pública. 2013. URL: <https://creativecommons.org/licenses/by/4.0/> (visitado 17-12-2025).
- [21] Parlamento Europeo y Consejo de la Unión Europea. *Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de Inteligencia Artificial)*. Diario Oficial de la Unión Europea (DOUE), L 2024/1689. Jul. de 2024. URL: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj> (visitado 15-12-2025).
- [22] Boletín Oficial del Estado. *Real Decreto 817/2023, de 8 de noviembre, que establece un entorno controlado de pruebas para el ensayo del cumplimiento del Reglamento de IA*. Referencia: BOE-A-2023-22767. 2023. URL: <https://www.boe.es/boe/dias/2023/11/09/pdfs/BOE-A-2023-22767.pdf> (visitado 20-12-2025).

- [23] Boletín Oficial del Estado. *Real Decreto 729/2023, de 22 de agosto, por el que se aprueba el Estatuto de la Agencia Española de Supervisión de Inteligencia Artificial*. Referencia: BOE-A-2023-18911. 2023. URL: <https://www.boe.es/buscar/pdf/2023/BOE-A-2023-18911-consolidado.pdf> (visitado 20-12-2025).
- [24] Nicholas Carlini et al. «Extracting Training Data from Large Language Models». En: *30th USENIX Security Symposium (USENIX Security 21)*. USENIX Association, ago. de 2021, págs. 2633-2650. ISBN: 978-1-939133-24-3. URL: <https://www.usenix.org/conference/usenixsecurity21/presentation/carlini-extracting>.
- [25] Erico Tjoa y Cuntai Guan. «A Survey on Explainable Artificial Intelligence (XAI): Toward Medical XAI». En: *IEEE Transactions on Neural Networks and Learning Systems* 32.11 (nov. de 2021), págs. 4793-4813. ISSN: 2162-2388. DOI: 10.1109/tnnls.2020.3027314. URL: <http://dx.doi.org/10.1109/TNNLS.2020.3027314>.
- [26] Ziwei Ji et al. «Survey of Hallucination in Natural Language Generation». En: *ACM Computing Surveys* 55.12 (mar. de 2023), págs. 1-38. ISSN: 1557-7341. DOI: 10.1145/3571730. URL: <http://dx.doi.org/10.1145/3571730>.
- [27] Elias Hossain et al. «Natural Language Processing in Electronic Health Records in relation to healthcare decision-making: A systematic review». En: *Computers in biology and medicine* 155 (2023), pág. 106649. DOI: 10.1016/j.compbiomed.2023.106649.
- [28] Guillem García Subies, Álvaro Barbero Jiménez y Paloma Martínez Fernández. *A Survey of Spanish Clinical Language Models*. 2023. arXiv: 2308.02199 [cs.CL]. URL: <https://arxiv.org/abs/2308.02199>.
- [29] Aurélie Névél et al. «Clinical Natural Language Processing in languages other than English: Opportunities and challenges». En: *Journal of biomedical semantics* 9 (mar. de 2018), pág. 12. DOI: 10.1186/s13326-018-0179-8.
- [30] Yu Wang et al. «Enhancing biomedical named entity recognition with parallel boundary detection and category classification». En: *BMC Bioinformatics* 26 (2025). DOI: 10.1186/s12859-025-06086-4.
- [31] Jiao Li et al. «BioCreative V CDR task corpus: a resource for chemical disease relation extraction». En: *Database: The Journal of Biological Databases and Curation* 2016 (2016). DOI: 10.1093/database/baw068.
- [32] Ling Luo et al. «BioRED: a rich biomedical relation extraction dataset». En: *Briefings in Bioinformatics* 23 (2022). DOI: 10.1093/bib/bbac282.
- [33] Özlem Uzuner et al. «2010 i2b2/VA challenge on concepts, assertions, and relations in clinical text». En: *Journal of the American Medical Informatics Association* 18.5 (jun. de 2011), págs. 552-556. ISSN: 1067-5027. DOI: 10.1136/amiajnl-2011-000203. eprint: <https://academic.oup.com/jamia/article-pdf/18/5/552/33015279/18-5-552.pdf>. URL: <https://doi.org/10.1136/amiajnl-2011-000203>.
- [34] Davy Weissenbacher et al. «Overview of the Fourth Social Media Mining for Health (SMM4H) Shared Tasks at ACL 2019». En: *Proceedings of the Fourth Social Media Mining for Health Applications (#SMM4H) Workshop & Shared Task*. Ed. por Davy Weissenbacher y Graciela Gonzalez-Hernandez. Florence, Italy: Association for Computational Linguistics, ago. de 2019, págs. 21-30. DOI: 10.18653/v1/W19-3203. URL: <https://aclanthology.org/W19-3203/>.

- [35] Sergio Rubio-Martín et al. «Early Detection of Autism Spectrum Disorder through AI-Powered Analysis of Social Media Texts». En: *2023 IEEE 36th International Symposium on Computer-Based Medical Systems (CBMS)*. 2023, págs. 235-240. DOI: 10.1109/CBMS58004.2023.00223.
- [36] Anne-Lyse Minard et al. *European Clinical Case Corpus*. European Language Grid. Dataset (Text corpus). Ago. de 2021.
- [37] Guillem García Subies, Álvaro Barbero Jiménez y Paloma Martínez Fernández. *ClinText-SP and RigoBERTa Clinical: a new set of open resources for Spanish Clinical NLP*. 2025. arXiv: 2503.18594 [cs.CL]. URL: <https://arxiv.org/abs/2503.18594>.
- [38] Salvador Lima-López et al. «Overview of SympTEMIST at BioCreative VIII: corpus, guidelines and evaluation of systems for the detection and normalization of symptoms, signs and findings from text». En: *Proceedings of the BioCreative VIII Challenge and Workshop: Curation and Evaluation in the era of Generative Models*. 2023, pág. 11.
- [39] Salvador Lima-López et al. «Overview of multicardioner task at bioasq 2024 on medical speciality and language adaptation of clinical ner systems for spanish, english and italian». En: *CLEF Working Notes* (2024).
- [40] Montserrat Marimon, Jorge Vivaldi y Núria Bel Rafecas. «Annotation of negation in the IULA Spanish Clinical Record Corpus». En: *Proceedings of the Workshop Computational Semantics Beyond Events and Roles (SemBEaR)*. Valencia, Spain: Association for Computational Linguistics, 2017, págs. 43-52.
- [41] Ander Intxaurrenondo et al. «Finding mentions of abbreviations and their definitions in Spanish clinical cases: The BARR2 shared task evaluation results». En: *Proceedings of the Iberian Languages Evaluation Forum (IberEval 2018)*. Vol. 2150. CEUR-WS.org, 2018, págs. 280-289.
- [42] Montserrat Marimon et al. «Automatic De-identification of Medical Texts in Spanish: the MEDDOCAN Track, Corpus, Guidelines, Methods and Evaluation of Results.» En: *IberLEF@ SEPLN*. 2019, págs. 618-638.
- [43] Aitor Gonzalez-Agirre et al. «PharmaCoNER: Pharmacological Substances, Compounds and proteins Named Entity Recognition track». En: *Proceedings of the 5th Workshop on BioNLP Open Shared Tasks*. Ed. por Kim Jin-Dong et al. Hong Kong, China: Association for Computational Linguistics, nov. de 2019, págs. 1-10. DOI: 10.18653/v1/D19-5701. URL: <https://aclanthology.org/D19-5701/>.
- [44] A Miranda-Escalada, E Farré y M Krallinger. «Named entity recognition, concept normalization and clinical coding: Overview of the cantemist track for cancer text mining in spanish, corpus, guidelines, methods and results». En: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2020), CEUR Workshop Proceedings*. 2020.
- [45] Antonio Miranda-Escalada et al. «Overview of automatic clinical coding: Annotations, guidelines, and solutions for non-english clinical cases at CodiEsp track of CLEF ehealth 2020.» En: *CLEF (Working Notes) 2020* (2020).
- [46] Salvador Lima et al. «NUBes: A corpus of negation and uncertainty in Spanish clinical texts». En: *arXiv preprint arXiv:2004.01092* (2020).
- [47] Pablo Báez et al. *The chilean waiting list corpus*. Nov. de 2020.
- [48] Alejandro Piad-Morfis et al. «Overview of the ehealth knowledge discovery challenge at iberlef 2021». En: *Procesamiento del Lenguaje Natural 67.0* (2021), págs. 233-242.

- [49] Salvador Lima-López et al. «NLP applied to occupational health: MEDDOPROF shared task at IberLEF 2021 on automatic recognition, classification and normalization of professions and occupations from medical texts». En: *Procesamiento del Lenguaje Natural* 67 (2021), págs. 243-256.
- [50] Leonardo Campillos-Llanos et al. «A clinical trials corpus annotated with UMLS® entities to enhance the access to evidence-based medicine». En: *BMC Medical Informatics and Decision Making* 21.1 (2021), págs. 1-19.
- [51] Luis Gasco Sánchez et al. «The SocialDisNER shared task on detection of disease mentions in health-relevant content from social media: methods, evaluation, guidelines and corpora». En: *Proceedings of The Seventh Workshop on Social Media Mining for Health Applications, Workshop & Shared Task*. 2022, págs. 182-189.
- [52] Antonio Miranda-Escalada et al. «Mention detection, normalization & classification of species, pathogens, humans and food in clinical documents: Overview of LivingNER shared task and resources». En: *Procesamiento del Lenguaje Natural* 69 (2022), págs. 241-253.
- [53] Salvador Lima-López et al. «MEDDOPLACE Shared Task overview: recognition, normalization and classification of locations and patient movement in clinical texts». En: *Procesamiento del Lenguaje Natural* 71 (2023), págs. 301-311.
- [54] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.
- [55] Jacob Devlin et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. 2019. arXiv: 1810.04805 [cs.CL]. URL: <https://arxiv.org/abs/1810.04805>.
- [56] Yinhan Liu et al. *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. 2019. arXiv: 1907.11692 [cs.CL]. URL: <https://arxiv.org/abs/1907.11692>.
- [57] Casimiro Pio Carrino et al. «Pretrained Biomedical Language Models for Clinical NLP in Spanish». En: *Proceedings of the 21st Workshop on Biomedical Language Processing*. Dublin, Ireland: Association for Computational Linguistics, mayo de 2022, págs. 193-199. DOI: 10.18653/v1/2022.bionlp-1.19. URL: <https://aclanthology.org/2022.bionlp-1.19>.
- [58] Vincenzo Moscato, Marco Postiglione, Giancarlo Sperlí et al. «Biomedical Spanish Language Models for entity recognition and linking at BioASQ DisTEMIST.» En: *CLEF (Working Notes)*. 2022, págs. 315-324.
- [59] Tiago Almeida et al. «BIT. UA at MedProcNer: Discovering Medical Procedures in Spanish Using Transformer Models with MCRF and Augmentation.» En: *CLEF (Working Notes)*. 2023, págs. 60-72.
- [60] Richard AA Jonker, Tiago Melo Almeida y Sérgio Matos. «BIT. UA at MultiCardioNER: Adapting a Multi-head CRF for Cardiology.» En: *CLEF (Working Notes)*. 2024, págs. 150-158.
- [61] Alexis Conneau et al. «Unsupervised Cross-lingual Representation Learning at Scale». En: *CoRR* abs/1911.02116 (2019). arXiv: 1911.02116. URL: <http://arxiv.org/abs/1911.02116>.
- [62] Instituto de Ingeniería del Conocimiento. *RigoBERTa-2.0*. 2025. DOI: 10.57967/hf/7048. URL: <https://huggingface.co/IIC/RigoBERTa-2.0>.
- [63] Lukas Lange et al. «CLIN-X: pre-trained language models and a study on cross-task transfer for concept extraction in the clinical domain». En: *CoRR* abs/2112.08754 (2021). arXiv: 2112.08754. URL: <https://arxiv.org/abs/2112.08754>.

-
- [64] Elena Zotova et al. «VICOMTECH at MedProcNER 2023: Transformers-based Sequence-labelling and Cross-encoding for Entity Detection and Normalisation in Spanish Clinical Texts.» En: *CLEF (Working Notes)*. 2023, págs. 206-218.
- [65] Sylvia Vassileva et al. «Fusion@ BioASQ MedProcNER: Transformer-based Approach for Procedure Recognition and Linking in Spanish Clinical Text.» En: *CLEF (Working Notes)*. 2023, págs. 190-205.
- [66] Anna Aksenova et al. «Transformer-Based Disease and Drug Named Entity Recognition in Multilingual Clinical Texts: MultiCardioNER challenge.» En: *CLEF (Working Notes)*. 2024, págs. 35-46.
- [67] Edward J Hu et al. «Lora: Low-rank adaptation of large language models.» En: *Iclr* 1.2 (2022), pág. 3.
- [68] Tim Dettmers et al. *QLoRA: Efficient Finetuning of Quantized LLMs*. 2023. arXiv: 2305.14314 [cs.LG]. URL: <https://arxiv.org/abs/2305.14314>.
- [69] Albert Q. Jiang et al. *Mistral 7B*. 2023. arXiv: 2310.06825 [cs.CL]. URL: <https://arxiv.org/abs/2310.06825>.
- [70] Alexander H. Liu et al. *Ministral 3*. 2026. arXiv: 2601.08584 [cs.CL]. URL: <https://arxiv.org/abs/2601.08584>.
- [71] Yanis Labrak et al. «BioMistral: A Collection of Open-Source Pretrained Large Language Models for Medical Domains». En: *Findings of the Association for Computational Linguistics: ACL 2024*. Ed. por Lun-Wei Ku, Andre Martins y Vivek Srikumar. Bangkok, Thailand: Association for Computational Linguistics, ago. de 2024, págs. 5848-5864. DOI: 10.18653/v1/2024.findings-acl.348. URL: <https://aclanthology.org/2024.findings-acl.348/>.
- [72] Aaron Grattafiori et al. *The Llama 3 Herd of Models*. 2024. arXiv: 2407.21783 [cs.AI]. URL: <https://arxiv.org/abs/2407.21783>.
- [73] Aitor Gonzalez-Agirre et al. *Salamandra Technical Report*. 2025. arXiv: 2502.08489 [cs.CL]. URL: <https://arxiv.org/abs/2502.08489>.
- [74] An Yang et al. *Qwen3 Technical Report*. 2025. arXiv: 2505.09388 [cs.CL]. URL: <https://arxiv.org/abs/2505.09388>.
- [75] Explosion. *spaCy: Industrial-strength Natural Language Processing in Python*. 2025. URL: <https://spacy.io/>.
- [76] Michael Han Daniel Han y Unsloth team. *Unsloth*. 2023. URL: <https://github.com/unslothai/unsloth>.

Apéndice A

Anexo

A.1. Prompts para DisTEMIST (Enfermedades)

El modelo decodificador recibe en cada inferencia un prompt estructurado. El turno de sistema define las reglas de extracción:

```
Actua como un sistema NER medico de alta precision.
REGLAS DE EXTRACCION:
1. Extrae exclusivamente entidades de tipo ENFERMEDAD.
2. COPIA Y PEGA de forma literal: No cambies mayusculas, minusculas ni tildes.
3. PROHIBIDO USAR SINONIMOS: Si el texto dice 'neoplasia', no escribas 'cancer'.
4. REPETICIONES: Si una enfermedad aparece varias veces en el texto, debes listarla varias veces en lineas separadas.
5. ORDEN: Extrae las menciones en el mismo orden en que aparecen en el texto.
6. FORMATO: Unicamente el texto de la mencion, una por linea. PROHIBIDO usar caracteres de lista al inicio.
7. Si no hay nada, devuelve un texto vacio.
```

El turno de usuario base sigue siempre la misma estructura:

```
Texto para analizar:
{texto de la oración}
```

Para la configuración *few-shot*, se inyectan cinco ejemplos de demostración previos a la consulta real, estructurados como turnos históricos de usuario y asistente. Esto permite guiar el formato de salida:

Ejemplo 1

Usuario: Con el diagnóstico de hipernefroma se realizó nefrectomía. La anatomía patológica fue de carcinoma de células renales del tipo de células claras de 8 cm de diámetro con invasión tumoral del uréter y de la vena renal. Tres meses después de la cirugía, la radiografía mostraba múltiples imágenes nodulares compatibles con metástasis.

Asistente:

hipernefroma
carcinoma de células renales del tipo de células claras de 8 cm de diámetro con invasión tumoral del uréter y de la vena renal
metástasis

Ejemplo 2

Usuario: Había sido fumador de 10 cigarrillos/día. No era consumidor de bebidas alcohólicas, no tenía hábitos tóxicos ni tomaba regularmente ningún medicamento. No refería antecedentes de muerte súbita ni de síncope. Tras realizar un test de flecainida, se realizó un diagnóstico de SB.

Asistente:

fumador
consumidor de bebidas alcohólicas
hábitos tóxicos
muerte súbita
síncope
SB

Ejemplo 3

Usuario: El paciente presenta fístula urinaria con abundante salida de orina e infección de herida quirúrgica. Tras la estabilización, se observa desaparición de fístula urinaria y necrosis grasa. Con el diagnóstico de fístula vésico-rectal se indica sondaje vesical hasta resolución de infección de herida quirúrgica.

Asistente:

fístula urinaria
infección de herida quirúrgica
fístula urinaria
necrosis grasa
fístula vésico-rectal
infección de herida quirúrgica

Ejemplo 4

Usuario: La tomografía reveló agenesia de cuerpo calloso aunada a un lipoma con bordes irregulares; espina bífida oculta a nivel de columna cervical y fisura central a nivel de la arcada del maxilar superior. Neurológicamente, a pesar de presentar agenesia del cuerpo calloso, se mantiene alerta y sin crisis convulsivas.

Asistente:

agenesia de cuerpo calloso

lipoma

espina bífida oculta a nivel de columna cervical

fisura central a nivel de la arcada del maxilar superior

agenesia del cuerpo calloso

crisis convulsivas

Ejemplo 5

Usuario: El paciente se lesionó ambos ojos concentrando los rayos solares con ayuda de una lupa buscando un fin estético. Asimismo se autoinduce unas quemaduras de segundo y tercer grado en la piel de la cara y los brazos para hacer desaparecer unos supuestos quistes.

Asistente:

se lesionó ambos ojos concentrando los rayos solares con ayuda de una lupa

se autoinduce unas quemaduras

quemaduras de segundo y tercer grado en la piel de la cara y los brazos

quistes

A.2. Prompts para ProcTEMIST (Procedimientos)

De forma análoga, para la extracción de procedimientos se adapta el turno de sistema:

```
Actua como un sistema NER medico de alta precision.

REGLAS DE EXTRACCION:
1. Extrae exclusivamente entidades de tipo PROCEDIMIENTO medico
(exploraciones, pruebas diagnosticas, intervenciones, tratamientos,
cirugias, etc.).
2. COPIA Y PEGA de forma literal: No cambies mayusculas, minusculas ni
tildes.
3. PROHIBIDO USAR SINONIMOS: Si el texto dice 'radiografia', no escribas
'Rx'.
4. REPETICIONES: Si un procedimiento aparece varias veces en el texto,
debes listarlo varias veces en lineas separadas.
5. ORDEN: Extrae las menciones en el mismo orden en que aparecen en el
texto.
6. FORMATO: Unicamente el texto de la mencion, una por linea. PROHIBIDO
usar caracteres de lista al inicio.
7. Si no hay nada, devuelve un texto vacio.
```

En la configuración *few-shot* se emplean fragmentos de texto etiquetando exclusivamente los procedimientos para guiar la atención del modelo hacia este tipo de entidades. A continuación se detallan los casos de demostración utilizados:

Ejemplo 1

Usuario: En la exploración física destaca palidez de piel, Tª: 37,2 °C y en la auscultación pulmonar crepitantes en base derecha.

Asistente:

exploración física
auscultación pulmonar

Ejemplo 2

Usuario: Paciente de 38 años, con amputación de antepié izquierdo por arteriopatía por enfermedad de Buerger.

Asistente:

amputación de antepié izquierdo

Ejemplo 3

Usuario: Dada la edad de la enferma y con el diagnóstico de neoplasia de cabeza de páncreas, se optó por tratamiento paliativo con colocación de endoprótesis (endoprótesis biliar tipo wall stent de 10 x 70 mm de longitud) quedando alojada desde colédoco proximal hasta el interior de la luz duodenal.

Asistente:

tratamiento paliativo
colocación de endoprótesis
endoprótesis biliar tipo wall stent

Ejemplo 4

Usuario: La paciente se mantuvo en DPA hasta agosto de 2002, momento en el que se le realiza un trasplante renal, precisando trasplantectomía por trombosis.

Asistente:

DPA

trasplante renal

trasplantectomía

Ejemplo 5

Usuario: Los padres activaban el aparato en casa para lograr la expansión y una vez por semana nosotros modificábamos la tensión de las cadenas para lograr la retrusión de la premaxila.

Asistente:

expansión

modificábamos la tensión de las cadenas

retrusión de la premaxila